

Multimodal Audio-Visual Deepfake Detection on MAVOS-DD with Synthetic Speech and Generated Video Extensions

Γραμματικόπουλος Φαίδων
Ξενάκη Μαρία

Μάθημα: Μηχανική Μάθηση σε Πολυμεσικά Δεδομένα
Διδάσκοντες: Θ. Γιαννακόπουλος - Η. Μαγκλογιάννης

University of Piraeus & NCSR Demokritos, Greece
June 2026

Περιεχόμενα

1 Εισαγωγή	1
1.1 Διατύπωση προβλήματος	1
1.2 Γιατί χρειάζεται πολυτροπική ένδειξη	2
1.3 Συνεισφορές	2
2 Σχετική Βιβλιογραφία	3
2.1 Το Ηχητικό anti-spoofing και συνθετική ομιλία	3
2.2 Αυτοεπιβλεπόμενες αναπαραστάσεις ομιλίας	3
2.3 Βάσεις Mel-spectrogram CNN	3
2.4 Οπτική ανίχνευση deepfake	4
2.5 Οπτικοακουστικός συγχρονισμός	4
2.6 Οπτικοακουστικές αυτοεπιβλεπόμενες αναπαραστάσεις	4
2.7 Μεροληψία συνόλων, codec και γενίκευση	4
3 Κατασκευή Συνόλου Δεδομένων	5
3.1 Αρχικό σύνολο και επιλογή υποσυνόλου	5
3.2 Παραγόμενος ήχος	5
3.3 Εξωτερικό σύνολο σύγχρονων παραγόμενων βίντεο	6
3.4 Ταξινόμια ετικετών	6
3.5 Πολιτική εκπαίδευσης και Data Leakage	6
3.6 Παράγωγα manifests	6
4 Μεθοδολογία	9
4.1 Ταξινομητές ηχητικών SSL αναπαραστάσεων	9
4.2 Βάση Mel-spectrogram CNN	9
4.3 Οπτικός ταξινομητής καρέ	10

4.4	Συγχρονισμός με lip landmarks και WavLM+BiGRU	10
4.5	Προεκπαιδευμένο SyncNet	10
4.6	Εναλλακτική οπτικοακουστική αναπαράσταση AV-HuBERT	10
4.7	Διορθωμένη οπτικοακουστική ανίχνευση βίντεο	11
4.8	Τελική σύντηξη	11
5	Πειράματα	12
5.1	Πρωτόκολλο εκπαίδευσης	12
5.2	Μετρικές	12
5.3	Συγκριτικά πειράματα	12
5.4	Έλεγχοι συγχυτικών παραγόντων	13
5.5	Εξωτερικό stress test	13
6	Αποτελέσματα	14
6.1	Ηχητικές βάσεις πλαστογράφησης	14
6.2	Ακουστικές συγχύσεις και κανονικοποίηση	14
6.3	Οπτική και οπτικοακουστική ανίχνευση ψεύτικου βίντεο	14
6.4	Συνέπεια συγχρονισμού	15
6.5	Τελικό Fusion	16
6.6	Εξωτερικό stress test σύγχρονων παραγόμενων βίντεο	17
7	Συζήτηση και Περιορισμοί	20
7.1	Τι σημαίνουν και τι δεν σημαίνουν οι αριθμοί	20
7.2	Οπτικές και οπτικοακουστικές κεφαλές	20
7.3	Η συνέπεια συγχρονισμού δεν είναι ανίχνευση deepfake	21
7.4	Εξωτερικά παραγόμενα βίντεο και ποσοστό εντοπισμού	21
7.5	Η τελική σύντηξη κληρονομεί τις εισόδους της	21
7.6	Απειλές εγκυρότητας	22
8	Συμπεράσματα	23

Κεφάλαιο 1

Εισαγωγή

Η ανίχνευση deepfake παρουσιάζεται συχνά ως ένα απλό δυαδικό πρόβλημα: δίνεται ένα ηχητικό απόσπασμα και ζητείται να αποφασίσουμε αν έχει παραχθεί τεχνητά. Στην πράξη, όμως, τα περισσότερα δείγματα που θα κληθεί να αξιολογήσει ένα τέτοιο σύστημα είναι βίντεο: περιέχουν ηχητικό κανάλι, ορατό ομιλητή και χρονική σχέση ανάμεσα στα δύο. Το προφανές ερώτημα, «είναι συνθετικός ο ήχος;», είναι μόνο ένα από τα ερωτήματα που μπορεί να τεθεί για το ίδιο κλιπ, και δεν αρκεί για τα σύγχρονα παραγόμενα βίντεο που διαθέτουν πειστικό και συγχρονισμένο εγγενή ήχο. Για αυτό η παρούσα εργασία αντιμετωπίζει την οπτικοακουστική ανίχνευση deepfake ως σύνολο διακριτών αλλά συγγενών όψεων, καθεμία από τις οποίες απαντά διαφορετική ερώτηση για το ίδιο δείγμα.

1.1 Διατύπωση προβλήματος

Η μελέτη βασίζεται σε περιορισμένο υποσύνολο του MAVOS-DD [8], επεκταμένο με συνθετικά παραγόμενη ομιλία TTS και με μικρή εξωτερική συλλογή σύγχρονων παραγόμενων βίντεο. Διακρίνουμε πέντε όψεις ανίχνευσης:

- *ηχητική πλαστογράφηση* (audio spoofing: είναι η ομιλία παραγμένη;)
- *οπτική ανίχνευση ψεύτικου βίντεο* (είναι η εικόνα παραγμένη ή τροποποιημένη;)
- *συνέπεια συγχρονισμού ήχου και χειλιών* (ταιριάζει η κίνηση του στόματος με τον ήχο;)
- *ανίχνευση ψεύτικου βίντεο σε επίπεδο οπτικοακουστικού δείγματος* (είναι το βίντεο παραγμένο ακόμη και όταν ο εγγενής ήχος είναι καλά συγχρονισμένος;)
- *τελική σύντηξη/fusion* που συνδυάζει τις βαθμολογίες των επιμέρους κεφαλών.

Δύο λάθη σήμανσης επιβάλλουν αυτόν τον διαχωρισμό. Πρώτον, ο αρχικός ήχος από φακέλους παραγόμενου βίντεο, όπως EchoMimic ή MEMO, παραμένει πραγματικός ήχος

αν δεν έχει αντικατασταθεί από TTS ή speech-to-speech. Αν χαρακτηριστεί ως πλαστός, μολύνονται τόσο η ηχητική όψη όσο και η σύντηξη. Δεύτερον, ένα παραγόμενο βίντεο που διατηρεί τον δικό του συγχρονισμένο εγγενή ήχο εξακολουθεί να είναι ψεύτικο ως βίντεο, ακόμη και αν μια κεφαλή συγχρονισμού κρίνει ότι ήχος και χείλη ταιριάζουν. Η συνέπεια συγχρονισμού απαντά «συμφωνούν στόμα και ήχος;», όχι «είναι συνθετικό το βίντεο;».

1.2 Γιατί χρειάζεται πολυτροπική ένδειξη

Η ανίχνευση μόνο από ήχο μπορεί να είναι παραπλανητική. Οι σύγχρονοι πάροχοι TTS παράγουν καθαρή ομιλία με σταθερό ηχητικό κανάλι και διατηρούν φασματικά αποτυπώματα ανά πάροχο. Ένας ταξινομητής που εκπαιδεύεται σε τέτοιο μίγμα μπορεί να κορεστεί στο σύνολο επικύρωσης χωρίς να έχει μάθει γενικεύσιμα χαρακτηριστικά φυσικότητας ομιλίας. Η οπτική ανίχνευση είναι ισχυρή στους σημερινούς παρόχους παραγόμενου βίντεο, αλλά μπορεί επίσης να υπερπροσαρμοστεί σε τεχνουργήματα γεννήτριας, ανάλυση, συμπίεση ή φόντο. Η συνέπεια συγχρονισμού εντοπίζει χονδρικές ασυμφωνίες στόματος και ήχου, αλλά δεν μπορεί να απορρίψει βίντεο που είναι συνθετικά και ταυτόχρονα καλά συγχρονισμένα. Μόνο η κοινή ανάγνωση ήχου, εικόνας, συγχρονισμού και οπτικοακουστικής υπογραφής μπορεί να διαχωρίσει αυτά τα σενάρια.

1.3 Συνεισφορές

Συνολικά, η εργασία δεν περιορίζεται στην εκπαίδευση ενός ακόμη δυαδικού ταξινομητή, αλλά οργανώνει ολόκληρο τον πειραματικό χώρο γύρω από σωστές ετικέτες και ελεγχόμενες πηγές μεροληψίας. Κατασκευάζεται ένα ντετερμινιστικό, περιορισμένο οπτικοακουστικό υποσύνολο από το MAVOS-DD, με φιλτράρισμα αγγλικών βίντεο, στρωματοποιημένες διασπάσεις ανά πηγή και χωριστά manifests για ήχο, εικόνα, συγχρονισμό και σύντηξη. Πάνω σε αυτό προστίθεται συνθετική ομιλία από εμπορικούς παρόχους TTS/STS (Google Cloud Text-to-Speech Neural2, OpenAI tts-1, ElevenLabs) με τις διασπάσεις να κληρονομούνται από το αρχικό βίντεο ώστε να περιορίζεται η διαρροή απομαγνητοφώνησης. Παράλληλα, εξετάζονται οι ρηχοί ακουστικοί παράγοντες μέσω codec matching και κανονικοποίησης EBU R128, δείχνοντας ότι τα συντομευτικά σήματα καναλιού μειώνονται αλλά δεν εξαφανίζονται. Η αξιολόγηση περιλαμβάνει συγκρίσιμες ηχητικές βάσεις SSL (Wav2Vec2, WavLM, HuBERT), βάση Mel-CNN, οπτική βάση EfficientNetB0 και ResNet50, κεφαλές συγχρονισμού WavLM+BiGRU και SyncNet/AV-HuBERT, καθώς και διορθωμένη οπτικοακουστική ανίχνευση σε επίπεδο βίντεο, όπου τα παραγόμενα βίντεο με εγγενή ήχο παραμένουν θετικά παραδείγματα. Τέλος, ο έλεγχος fixed25, το εξωτερικό Higgsfield stress test και η σύντηξη βαθμονομημένων βαθμολογιών χρησιμοποιούνται για να φανεί όχι μόνο πού αποδίδουν τα μοντέλα, αλλά και ποιες συντομεύσεις ή ασάφειες ετικετών μπορούν να κάνουν ένα υψηλό αποτέλεσμα παραπλανητικό.

Κεφάλαιο 2

Σχετική Βιβλιογραφία

2.1 Το Ηχητικό anti-spoofing και συνθετική ομιλία

Η σειρά ASVspoof [12] καθιέρωσε τυποποιημένα σημεία αναφοράς για διάκριση πλαστογραφημένης και γνήσιας ομιλίας, επιταχύνοντας την έρευνα τόσο σε επιθέσεις replay όσο και σε εξόδους text-to-speech ή voice conversion. Η πρόσφατη βιβλιογραφία μετακινείται από χειροποίητα χαρακτηριστικά προς προεκπαιδευμένες αναπαραστάσεις ήχου, ενώ παράλληλα αναδεικνύει ότι συντομεύσεις ανά κανάλι μπορούν να διογκώσουν τα αποτελέσματα επικύρωσης χωρίς αντίστοιχη γενίκευση στον πραγματικό κόσμο [2]. Η παρούσα εργασία ακολουθεί την κατεύθυνση των προεκπαιδευμένων αναπαραστάσεων, αλλά αντιμετωπίζει αυτές τις συντομεύσεις ως βασική απειλή εγκυρότητας.

2.2 Αυτοεπιβλεπόμενες αναπαραστάσεις ομιλίας

Οι παγωμένοι SSL κωδικοποιητές αποτελούν πλέον τυπικό εξαγωγέα χαρακτηριστικών για ταξινόμηση ομιλίας. Χρησιμοποιούμε Wav2Vec2 [1], WavLM [3] και HuBERT [6], στη βασική διαμόρφωση των 768 διαστάσεων. Τα μοντέλα αυτά σχεδιάστηκαν κυρίως για αναγνώριση ομιλίας και συγγενείς εργασίες. Η πολύ ισχυρή επίδοσή τους στο anti-spoofing ήχου είναι ένα από τα φαινόμενα που πρέπει να ερμηνευθούν προσεκτικά.

2.3 Βάσεις Mel-spectrogram CNN

Τα λογαριθμικά mel spectrograms παραμένουν ανταγωνιστική είσοδος για συμπαγείς CNN ταξινομητές σε εργασίες αντι-πλαστογράφησης ήχου. Περιλαμβάνουμε μια βάση Mel-CNN ως ελαφριά σύγκριση και ως γέφυρα ερμηνευσιμότητας: αν η διαχωρισιμότητα επιβιώνει στο επίπεδο των mel χαρακτηριστικών μετά την κανονικοποίηση, τότε χαμηλού επιπέδου φασματικές ενδείξεις εξακολουθούν να υπάρχουν πέρα από το απλό codec matching.

2.4 Οπτική ανίχνευση deepfake

Αρχιτεκτονικές συνέλιξης όπως ResNet [5] και EfficientNet [11] είναι καθιερωμένες βάσεις για ανίχνευση deepfake σε επίπεδο καρέ. Η βιβλιογραφία έχει δείξει ότι οι οπτικοί ταξινομητές συχνά μαθαίνουν τεχνουργήματα συγκεκριμένης γεννήτριας ή χαρακτηριστικά του συνόλου δεδομένων [7]. Αυτό σχετίζεται άμεσα με τη δική μας παρατήρηση ότι η ανάκληση ανά πηγή διαφέρει έντονα ανάμεσα στους παρόχους παραγόμενου βίντεο.

2.5 Οπτικοακουστικός συγχρονισμός

Το SyncNet [4] εισήγαγε ένα αντιθετικό μοντέλο ευθυγράμμισης ήχου και στόματος και έκτοτε χρησιμοποιείται συχνά για μέτρηση συμβατότητας χειλιών και ήχου. Στο Wav2Lip [9], ένας προεκπαιδευμένος «ειδικός» συγχρονισμού τύπου SyncNet χρησιμοποιείται ως απώλεια/κριτής συγχρονισμού, ώστε το παραγόμενο βίντεο ομιλητή να ευθυγραμμίζεται καλύτερα με το ηχητικό σήμα. Στην παρούσα εργασία το χρησιμοποιούμε ως διαγνωστικό συγχρονισμού και ως ένα από τα σήματα της διορθωμένης οπτικοακουστικής κεφαλής βίντεο.

2.6 Οπτικοακουστικές αυτοεπιβλεπόμενες αναπαραστάσεις

Το AV-HuBERT [10] μεταφέρει την ιδέα της μάσκας και πρόβλεψης κρυφών μονάδων του HuBERT στο οπτικοακουστικό πεδίο, μαθαίνοντας κοινές αναπαραστάσεις από ηχητικά χαρακτηριστικά και οπτικές ακολουθίες κίνησης στόματος. Η σημασία του για την παρούσα εργασία είναι ότι δεν περιορίζεται σε μια χειροποίητη μετρική συγχρονισμού, αλλά παρέχει πλούσια αναπαράσταση του συνδυασμού ομιλίας και κίνησης χειλιών. Για αυτό αξιολογείται ως σύγχρονη οπτικοακουστική βάση στην ανίχνευση ψεύτικου βίντεο επιπέδου κλιπ, παράλληλα με το πιο κλασικό SyncNet. Τα αποτελέσματα, ωστόσο, διαχωρίζονται ανά εργασία: η ισχύς του ως γενική οπτικοακουστική αναπαράσταση δεν συνεπάγεται απαραίτητα καλύτερη επίδοση στην καθαρή διάγνωση ασυγχρονίας.

2.7 Μεροληψία συνόλων, codec και γενίκευση

Επαναλαμβανόμενο θέμα στη βιβλιογραφία ανίχνευσης deepfake είναι ότι σχεδόν τέλεια αποτελέσματα στο ίδιο σύνολο αξιολόγησης μπορεί να κρύβουν συγχυτικούς παράγοντες ανά σύνολο, πάροχο ή codec. Αυτό αποτελεί το βασικό μοντέλο απειλής της αναφοράς: ο ακουστικός έλεγχος συγχύσεων και ο έλεγχος σταθερού παραθύρου υπάρχουν για να αποκαλύπτουν, και όχι να κρύβουν, συντομεύσεις που επιβιώνουν της απλής προεπεξεργασίας.

Κεφάλαιο 3

Κατασκευή Συνόλου Δεδομένων

Το σύνολο δεδομένων κατασκευάζεται με περιορισμό, επανασήμανση και επέκταση υποσυνόλου του MAVOS-DD. Επιλέγουμε ανώτατα όρια ανά πηγή αντί για χρήση ολόκληρου του σώματος, ώστε η εκπαίδευση και η εξαγωγή χαρακτηριστικών να παραμένουν εφικτές σε έναν σταθμό εργασίας και οι μετρήσεις ανά πηγή να είναι αρκετά ισορροπημένες. Το υποσύνολο αυτό περιλαμβάνει 4149 βίντεο σε πέντε φακέλους πηγής (Πίνακας 3.1).

3.1 Αρχικό σύνολο και επιλογή υποσυνόλου

Το MAVOS-DD [8] ανακτάται από το Hugging Face (unibuc-cs/MAVOS-DD), φιλτράρεται στα αγγλικά και περιορίζεται με σταθερά ανώτατα όρια ανά φάκελο πηγής πριν από τη λήψη. Το τελικό υποσύνολο καλύπτει πραγματικά βίντεο και τέσσερις παρόχους παραγόμενου βίντεο: EchoMimic, MEMO, LivePortrait και Sonic. Στους παραγόμενους φακέλους το οπτικό κανάλι είναι συνθετικό, αλλά ο ήχος είναι ο αρχικός γνήσιος ήχος που κληρονομείται από τον αγωγό του MAVOS-DD. Αυτή η διάκριση διατηρείται σε όλη τη σήμανση.

3.2 Παραγόμενος ήχος

Από κάθε βίντεο εξάγεται ήχος 16 kHz, μονοφωνικός. Υποσύνολο των κλιπ απομαγνητοφωνείται με Google Speech-to-Text V2. Στη συνέχεια παράγεται συνθετική ομιλία από τις απομαγνητοφωνήσεις με ElevenLabs, Google TTS και OpenAI TTS. Κάθε γραμμή παραγόμενου ήχου κληρονομεί τη διάσπαση του αρχικού βίντεο, ώστε η ίδια φράση ή ο ίδιος ομιλητής να μην εμφανίζεται ταυτόχρονα σε εκπαίδευση και validation.

3.3 Εξωτερικό σύνολο σύγχρονων παραγόμενων βίντεο

Για να ελεγχθεί η δύναμη του εκπαιδευόμενου μοντέλου σύντηξης (fusion), δημιουργήθηκαν 71 ai-generated video μέσω της χρήσης των state-of-the-Art μοντέλων εικόνας Higgsfield Soul 2.0 και Recraft V4.1 για ρεαλιστική εικόνα αναφοράς και των μοντέλων Kling 3.0 και Gemini Omni Flash για την δημιουργία του video ομιλίας. Τα κλιπ αυτά χρησιμοποιούνται μόνο ως θετικό stress test και ποτέ στην εκπαίδευση. Επειδή δεν υπάρχει αντίστοιχο πραγματικό σύνολο ελέγχου, ο αντίστοιχος πίνακας αναφέρει ποσοστό εντοπισμού και όχι ακρίβεια.

3.4 Ταξονομία ετικετών

Ο Πίνακας 3.2 συνοψίζει τις ετικέτες που χρησιμοποιούνται στις επιμέρους όψεις του προβλήματος. Ο βασικός διαχωρισμός είναι ότι κάθε όψη απαντά διαφορετική ερώτηση. Στην ηχητική όψη, ο αρχικός ήχος ενός βίντεο θεωρείται γνήσιος ακόμη και αν το οπτικό κανάλι προέρχεται από γεννήτρια, πλαστός χαρακτηρίζεται μόνο ο ήχος που έχει αντικατασταθεί από TTS ή speech-to-speech. Αντίθετα, στην οπτικοακουστική όψη επιπέδου βίντεο, τα παραγόμενα βίντεο παραμένουν θετικά δείγματα ακόμη και όταν ο εγγενής τους ήχος είναι καλά συγχρονισμένος με την κίνηση του στόματος. Με άλλα λόγια, ο συγχρονισμός είναι ένδειξη συνέπειας ανάμεσα σε δύο κανάλια, όχι απόδειξη ότι το βίντεο είναι πραγματικό. Αυτός ο διαχωρισμός αποτρέπει την εσφαλμένη εξίσωση «συγχρονισμένο = πραγματικό», η οποία θα οδηγούσε σε λανθασμένη εκπαίδευση και αξιολόγηση.

3.5 Πολιτική εκπαίδευσης και Data Leakage

Το σύνολο χωρίζεται με αναλογία 70/15/15 σε εκπαίδευση, επικύρωση και έλεγχο, με στρωματοποίηση ως προς `source_folder` και σταθερό seed 42. Η διάσπαση γίνεται στο επίπεδο του πηγαίου βίντεο και στη συνέχεια κληρονομείται από όλα τα παράγωγα δείγματα που προκύπτουν από αυτό. Έτσι, αν ένα βίντεο χρησιμοποιηθεί για παραγωγή συνθετικού ήχου ή για δημιουργία ζευγούς συγχρονισμού, όλες οι αντίστοιχες γραμμές παραμένουν στην ίδια πλευρά του διαχωρισμού. Με αυτόν τον τρόπο αποφεύγεται η διαρροή ομιλητή, περιεχομένου και απομαγνητοφώνησης ανάμεσα σε εκπαίδευση και επικύρωση. Το manifest ζευγών συγχρονισμού χρησιμοποιείται μόνο για train/val κατά την εκπαίδευση, ενώ το test split παραμένει προστατευμένο για την τελική αξιολόγηση.

3.6 Παράγωγα manifests

Κάτω από το `data/derived/` παράγονται τέσσερα κύρια manifests: ηχητικής πλαστογράφησης, οπτικής ομιλίας, σύντηξης και ζευγών συγχρονισμού. Αντιστοιχούν αντίστοιχα στις εργασίες γνήσιου/παραγόμενου ήχου, πραγματικού/παραγόμενου βίντεο, ευ-

Πίνακας 3.1: Υποσύνολο MAVOS-DD για τα πειράματα. Τα πραγματικά βίντεο ορίζουν τη γνήσια κλάση, ενώ οι τέσσερις πάροχοι παραγόμενου βίντεο ορίζουν την ψεύτικη κλάση στις οπτικές και οπτικοακουστικές όψεις.

Πηγή	# βίντεο	Ρόλος
real	2500	Γνήσιος ήχος και πραγματικό βίντεο
EchoMimic	600	Εγγενής ήχος, παραγόμενο βίντεο
MEMO	400	Εγγενής ήχος, παραγόμενο βίντεο
LivePortrait	314	Εγγενής ήχος, παραγόμενο βίντεο
Sonic	335	Εγγενής ήχος, παραγόμενο βίντεο
Σύνολο	4149	

Dataset and feature pipeline



Σχήμα 3.1: Αγωγός κατασκευής του συνόλου δεδομένων και των feature stores.

θυγραμμισμένων γραμμών για εκπαίδευση ήχου και εικόνας, και ταιριασμένων ή αταίριαστων ζευγών στόματος-ήχου.

Ο αγωγός συνοψίζεται διαγραμματικά στο Σχήμα 3.1.

Πίνακας 3.2: Ταξονομία ετικετών ανά όψη ανίχνευσης. Ο αρχικός ήχος από φακέλους παραγόμενου βίντεο παραμένει γνήσιος, εκτός αν αντικατασταθεί από TTS/STS. Ένα παραγόμενο βίντεο με τον δικό του εγγενή ήχο παραμένει ψεύτικο ακόμη και αν είναι συγχρονισμένο.

Όψη	Γνήσια κλάση	Ψεύτικη / ύποπτη κλάση
Ηχητική πλαστογράφηση	Αρχικός ήχος από πραγματικά και παραγόμενα βίντεο	Παραγόμενη ομιλία από ElevenLabs, Google TTS, OpenAI TTS ή STS
Οπτική ανίχνευση βίντεο	Πραγματικά βίντεο MAVOS-DD	EchoMimic, MEMO, LivePortrait, Sonic
Συνέπεια συγχρονισμού	Ταιριασμένα ζεύγη αρχικού βίντεο και ήχου	Παραγόμενος ήχος ίδιου κειμένου και αταίριαστα ζεύγη ήχου/βίντεο
Οπτικοακουστική ανίχνευση βίντεο	Πραγματικά βίντεο με εγγενή ήχο	EchoMimic, MEMO, LivePortrait, Sonic με εγγενή ήχο
Τελική σύντηξη	Πραγματικά βίντεο	Ενδείξεις παραγόμενης ομιλίας, παραγόμενης εικόνας, ασυνέπειας AV ή παραγόμενου βίντεο
Εξωτερικό stress test	Πραγματικό σύνολο αναφοράς όταν υπάρχει	Σύγχρονα παραγόμενα βίντεο τύπου Kling / Gemini / Higgsfield

Κεφάλαιο 4

Μεθοδολογία

Οι οικογένειες μοντέλων περιγράφονται θεωρητικά και όχι ως υλοποίηση κώδικα. Κάθε κεφαλή ανίχνευσης είναι ελαφρύς ταξινομητής πάνω σε συγκεκριμένα features. Το ακατέργαστο βίντεο χρησιμοποιείται για εξαγωγή χαρακτηριστικών, ανάλυση σφαλμάτων και πρόβλεψη μεμονωμένου κλιπ, αλλά όχι μέσα στον βρόχο εκπαίδευσης των μοντέλων feature-store.

4.1 Ταξινομητές ηχητικών SSL αναπαραστάσεων

Χρησιμοποιούνται τρεις παγωμένες βάσεις SSL: Wav2Vec2 [1], WavLM [3] και HuBERT [6]. Κάθε βάση επιστρέφει ακολουθία αναπαραστάσεων 768 διαστάσεων στα 50 Hz για είσοδο 16 kHz. Ο ήχος κόβεται σε σταθερό παράθυρο 4.0 s, μονοφωνικό στα 16 kHz, και κωδικοποιείται μία φορά εκτός γραμμής. Τα χαρακτηριστικά αποθηκεύονται ως float16 .npy αρχεία κάτω από data/features/audio_{backend}/. Η κεφαλή ταξινόμησης είναι ένα ρηχό MLP πάνω σε συγκεντρωτικά και ακολουθιακά χαρακτηριστικά και στοχεύει σε μία δυαδική ετικέτα audio_label: γνήσια έναντι παραγόμενης ομιλίας. Ο κίνδυνος είναι ότι η κεφαλή μαθαίνει αποτυπώματα παρόχου ή καναλιού αντί για γενικεύσιμα τεχνουργήματα σύνθεσης.

4.2 Βάση Mel-spectrogram CNN

Το Mel-CNN δέχεται λογαριθμικά mel spectrograms 128 ζωνών στο ίδιο παράθυρο 4.0 s και τα επεξεργάζεται με συμπαγές CNN. Λειτουργεί ως άμεση φασματική βάση χωρίς SSL προεκπαίδευση και ως γέφυρα ερμηνευσιμότητας για τον έλεγχο ακουστικών συγχύσεων, επειδή οι φασματικοί χάρτες αντιστοιχούν φυσικά στα ρηχά ακουστικά χαρακτηριστικά.

4.3 Οπτικός ταξινομητής καρέ

Η οπτική βάση είναι ταξινομητής εικόνας EfficientNetB0 [41] πάνω σε δειγματοληπτημένα καρέ κάθε βίντεο. Οι βαθμολογίες καρέ συγκεντρώνονται σε πρόβλεψη επιπέδου βίντεο. Η κεφαλή στοχεύει την οπτική όψη: πραγματικό βίντεο έναντι παραγόμενου βίντεο. Είναι η ισχυρότερη καθαρά οπτική βάση στους τέσσερις παρόχους, αλλά είναι μεροληπτικά ύποπτη: το notebook εντοπίζει ασύμπτωτες υπογραφές ανάλυσης/codec/fps ανά πηγή, άρα τα υψηλά αποτελέσματα πρέπει να αναφέρονται ως ισχυρή αλλά καναλικά-συγχυμένη οπτική βάση.

4.4 Συγχρονισμός με lip landmarks και WavLM+BiGRU

Η προσαρμοσμένη κεφαλή συγχρονισμού χρησιμοποιεί σημεία χειλιών MediaPipe (40 σημεία περιγράμματος και κανονικοποιημένο πλαίσιο χειλιών, στα 5 fps για παράθυρο 4 s) ως οπτικό κανάλι και παγωμένες αναπαραστάσεις WavLM ως ηχητικό κανάλι. Ένα BiGRU κωδικοποιεί την ακολουθία χειλιών και ένα MLP ομοιότητας συγκρίνει ήχο και χείλη. Η θετική κλάση στην εργασία συγχρονισμού είναι `async_inconsistent_pair`. Αυτό είναι διαγνωστικό ασυμφωνίας, όχι ανιχνευτής ψεύτικου βίντεο.

4.5 Προεκπαιδευμένο SyncNet

Αξιολογείται επιπλέον προεκπαιδευμένη κεφαλή SyncNet [4]. Οι είσοδοι είναι απόκομματα στόματος στα 25 fps και ηχητικά mel τμήματα. Λαμβάνουμε την ακολουθία συνημιτονικών ομοιοτήτων ανά παράθυρο, τη συμπυκνώνουμε σε επτά στατιστικά ανά κλιπ και περνάμε αυτά τα χαρακτηριστικά σε ρηχό ταξινομητή. Το SyncNet υπερέρχει ιδιαίτερα στον δύσκολο τύπο αρνητικού παραδείγματος `mismatched_original`, όπου πραγματικός ήχος συγκρίνεται με στόμα άλλου πραγματικού ομιλητή.

4.6 Εναλλακτική οπτικοακουστική αναπαράσταση AV-HuBERT

Το AV-HuBERT [10] περιλαμβάνεται ως ισχυρότερη οπτικοακουστική βάση. Η φόρτωση των βαρών απαιτεί `fairseq` και μικρή συμβατότητα εγγραφής του `hubconf`. Χρησιμοποιείται το `extract_finetune` για παραγωγή οπτικών και ηχητικών ακολουθιών, με ανασχηματισμό των οπτικών tokens σε $(T, 768)$. Το AV-HuBERT είναι η ισχυρότερη οπτικοακουστική βάση βίντεο που δοκιμάστηκε, αλλά όχι η ισχυρότερη καθαρή κεφαλή συγχρονισμού.

4.7 Διορθωμένη οπτικοακουστική ανίχνευση βίντεο

Η κεφαλή βίντεο απαντά «είναι αυτό παραγόμενο βίντεο;» και όχι «συμφωνούν στόμα και ήχος;». Τα πραγματικά βίντεο MAVOS-DD με εγγενή ήχο είναι η γνήσια κλάση. Τα EchoMimic, MEMO, LivePortrait και Sonic κλιπ με τον δικό τους εγγενή ήχο είναι η ψεύτικη κλάση. Έτσι διορθώνεται το κρίσιμο λάθος όπου ένα καλά συγχρονισμένο συνθετικό βίντεο θα θεωρούνταν πραγματικό.

Η υλοποίηση επαναχρησιμοποιεί τους κωδικοποιητές SyncNet ή AV-HuBERT, συγκεντρώνει τα χαρακτηριστικά ανά παράθυρο και εκπαιδεύει ρηχό ταξινομητή στον στόχο βίντεο. Ο έλεγχος fixed25 κόβει κάθε κλιπ στα 25 καρέ οπτικοακουστικού σήματος, ώστε να περιορίζεται η συντόμευση διάρκειας.

4.8 Τελική σύντηξη

Η τελική σύντηξη είναι σύντηξη βαθμολογιών και όχι ενιαίο end-to-end μοντέλο. Διαβάζει βαθμονομημένες βαθμολογίες όπως `audio_fake_score`, `sync_inconsistent_score` και `video_av_fake_score`. Η προβλεπόμενη οπτική βαθμολογία `visual_fake_score` δεν συμμετέχει στο τρέχον εκπαιδευσιμο stack, επειδή η βάση EfficientNetB0 υπάρχει μόνο ως σημειωματάριο και όχι ως σταθερό CLI/checkpoint. Συνεπώς τα τελικά αποτελέσματα σύντηξης πρέπει να διαβαστούν ως σύντηξη ήχου + ασυνέπειας συγχρονισμού + οπτικοακουστικής κεφαλής βίντεο, όχι ως πλήρης σύντηξη ήχου + εικόνας + συγχρονισμού + βίντεο.

Συγκρίνουμε κανόνα μεγίστου διαθέσιμου σήματος, logistic regression stacking ως προτιμώμενη ερμηνεύσιμη λύση, και μικρό MLP ως αφαίρεση. Η ταυτότητα παρόχου ή φακέλου πηγής απαγορεύεται ως χαρακτηριστικό: η σύντηξη μπορεί να συνδυάσει ενδείξεις που παρήγαγαν οι κεφαλές, όχι να εφεύρει νέα πληροφορία ούτε να απομνημονεύσει φακέλους.

Κεφάλαιο 5

Πειράματα

5.1 Πρωτόκολλο εκπαίδευσης

Οι κεφαλές εκπαιδεύονται με BCE loss και AdamW. Τα ακριβή υπερπαραμετρικά σχήματα διαφέρουν ανά κλάδο, αλλά όλα τα μοντέλα παραμένουν μικρά, με παγωμένες βάσεις χαρακτηριστικών και πρώιμη διακοπή στο validation ROC-AUC. Τα στατιστικά κανονικοποίησης υπολογίζονται μόνο στο train split. Το seed 42 ορίζεται σε κάθε σημείο εισόδου.

5.2 Μετρικές

Αναφέρονται οι βασικές μετρικές ταξινόμησης: ROC-AUC, EER με το αντίστοιχο κατώφλι, F1, precision, recall και πίνακας σύγχυσης. Όπου έχει νόημα, οι μετρικές αναλύονται επιπλέον ανά πάροχο ή ανά πηγή βίντεο. Στην κεφαλή συγχρονισμού, η βασική διαγνωστική μετρική είναι το recall της κατηγορίας `mismatched_original`: μετρά πόσο συχνά το μοντέλο εντοπίζει την περίπτωση όπου πραγματικός ήχος αντιστοιχίζεται με το στόμα διαφορετικού πραγματικού ομιλητή. Η συγκεκριμένη περίπτωση είναι σημαντική, επειδή δεν μπορεί να λυθεί απλώς από αποτυπώματα παρόχων TTS.

5.3 Συγκριτικά πειράματα

Τα συγκριτικά πειράματα οργανώνονται σε τέσσερις άξονες. Πρώτον, συγκρίνεται ο codec-matched ήχος με τον κανονικοποιημένο ήχο, ώστε να εκτιμηθεί η επίδραση των ακουστικών συντομεύσεων. Δεύτερον, στην ηχητική όψη συγκρίνονται οι βάσεις Wav2Vec2, WavLM και HuBERT. Τρίτον, στην εργασία συγχρονισμού συγκρίνονται η προσαρμοσμένη κεφαλή WavLM+BiGRU, το προεκπαιδευμένο SyncNet και το AV-HuBERT. Τέλος, στην οπτικοακουστική κεφαλή βίντεο συγκρίνεται το ανεξέλεγκτο χρονικό παράθυρο με τον έλεγχο `fixed25`. Στη σύντηξη εξετάζεται η συνεισφορά κάθε διαθέσιμης βαθμολογίας κεφαλής στο τελικό αποτέλεσμα.

5.4 Έλεγχοι συγχυτικών παραγόντων

Δύο έλεγχοι συνοδεύουν την εκπαίδευση. Ο ακουστικός έλεγχος προσαρμόζει ρηχούς ταξινομητές σε χειροποίητα χαρακτηριστικά (RMS, σιωπή, φασματικό κέντρο, rolloff, εύρος ζώνης, ενέργεια υψηλών συχνοτήτων και προαιρετικά F0) πριν και μετά την κανονικοποίηση EBU R128. Η πτώση ROC-AUC δείχνει πόσο ρηχό ακουστικό σήμα εξηγεί το αποτέλεσμα. Ο έλεγχος fixed25 περιορίζει τη διάρκεια των κλιπ στην οπτικοακουστική κεφαλή, ώστε να μετρηθούν συντομεύσεις χρονικού μήκους.

5.5 Εξωτερικό stress test

Το σύνολο Higgsfield βαθμολογείται με τις διαθέσιμες κεφαλές στο λειτουργικό κατώφλι τους. Το αποτέλεσμα είναι ποσοστό εντοπισμού θετικών δειγμάτων και όχι ακρίβεια, επειδή δεν υπάρχει αντιστοιχισμένο πραγματικό σύνολο ελέγχου.

Κεφάλαιο 6

Αποτελέσματα

6.1 Ηχητικές βάσεις πλαστογράφησης

Ο Πίνακας 6.1 παρουσιάζει τις τρεις ηχητικές βάσεις SSL στο codec-matched, φωνητικά ασύμπτωτο σύνολο επικύρωσης. Το Wav2Vec2 επιτυγχάνει ROC-AUC 0.9508 και EER 0.106. Το WavLM φτάνει σχεδόν σε πλήρη διαχωρισμό (ROC-AUC $\approx$ 0.99997, EER 0.006), ενώ το HuBERT φτάνει στο ανώτατο δυνατό αποτέλεσμα στο σύνολο επικύρωσης (ROC-AUC 1.0000, EER 0.000). Αν τα αποτελέσματα αυτά διαβαστούν απομονωμένα, η ηχητική ανίχνευση φαίνεται σχεδόν λυμένο πρόβλημα. Ο Πίνακας 6.2 και η συζήτηση που ακολουθεί δείχνουν γιατί αυτή η ερμηνεία είναι υπερβολικά αισιόδοξη.

6.2 Ακουστικές συγχύσεις και κανονικοποίηση

Ο Πίνακας 6.2 συγκρίνει τον ρηχό ακουστικό έλεγχο και το Mel-CNN πριν και μετά την κανονικοποίηση (EBU R128). Η λογιστική παλινδρόμηση πάνω σε ακουστικά χαρακτηριστικά πέφτει από ROC-AUC 0.9914 σε codec-matched ήχο σε 0.9713 μετά την κανονικοποίηση. Το random forest πέφτει από 0.9970 σε 0.9889. Το Mel-CNN παραμένει σχεδόν κορεσμένο, κοντά στο 0.99994. Η κατεύθυνση της μεταβολής είναι το κρίσιμο σημείο: η κανονικοποίηση μειώνει τη ρηχή διαχωρισιμότητα, αλλά δεν την εξαλείφει. Άρα ενδείξεις ακουστικής σκηνής και παρόχου επιβιώνουν ακόμη και μετά από εξίσωση έντασης και εύρους ζώνης.

6.3 Οπτική και οπτικοακουστική ανίχνευση ψεύτικου βίντεο

Η οπτική βάση EfficientNetB0 σε καρέ πετυχαίνει validation ROC-AUC 0.9853, EER 0.0671 και F1 0.9167. Η ανάκληση ανά πηγή είναι 1.00 για EchoMimic, MEMO και Sonic, αλλά μόνο 0.6596 για LivePortrait. Η ειδικότητα στα πραγματικά βίντεο είναι 0.9307. Το αποτέλεσμα είναι ισχυρό, αλλά όχι καθαρή απόδειξη ανίχνευσης ρεαλισμού προσώπου:

Πίνακας 6.1: Ηχητικές βάσεις πλαστογράφησης στο codec-matched, φωνητικά ασύμπτωτο σύνολο επικύρωσης. Όλες οι βάσεις είναι παγωμένοι SSL κωδικοποιητές 768 διαστάσεων με ίδιες MLP κεφαλές. Ο κορεσμός των WavLM και HuBERT πρέπει να διαβαστεί μαζί με τον έλεγχο ακουστικών συγχύσεων.

Βάση	ROC-AUC	EER	Ερμηνεία
Wav2Vec2	0.9508	0.106	Ισχυρό, όχι κορεσμένο
WavLM	0.99997	0.006	Σχεδόν κορεσμένο
HuBERT	1.0000	0.000	Κορεσμένο

Πίνακας 6.2: Πηχοί ακουστικοί έλεγχοι και Mel-CNN πριν και μετά την κανονικοποίηση. Η κανονικοποίηση μειώνει τη διαχωρισιμότητα, αλλά δεν την αφαιρεί.

Έλεγχος / μοντέλο	Codec ROC-AUC	Normalized ROC-AUC	Ερμηνεία
Acoustic LR probe	0.9914	0.9713	Μειωμένο, ακόμη υψηλό
Acoustic RF probe	0.9970	0.9889	Μειωμένο, ακόμη υψηλό
Mel-CNN baseline	≈ 1.0000	0.99994	Κορεσμένο


το ίδιο σημειωματάριο δείχνει ότι κάθε πηγή έχει διαφορετικό τεχνικό αποτύπωμα ως προς την ανάλυση, το codec και το fps.

Στην οπτικοακουστική κεφαλή επιπέδου βίντεο, το AV-HuBERT είναι ισχυρότερο από το SyncNet. Χωρίς έλεγχο παραθύρου, το ROC-AUC είναι 0.8703 για SyncNet και 0.9642 για AV-HuBERT. Με fixed25, οι τιμές πέφτουν σε 0.8468 και 0.9317 αντίστοιχα. Η πτώση από το ανεξέλεγκτο παράθυρο στο fixed25 μετρά συντόμευση χρονικής διάρκειας.

6.4 Συνέπεια συγχρονισμού

Ο Πίνακας 6.4 δείχνει τις κεφαλές συγχρονισμού. Η προσαρμοσμένη κεφαλή WavLM+BiGRU φτάνει ROC-AUC 0.8409 (EER 0.2527, F1 0.826), αλλά το `recall mismatched_original` είναι μόνο 0.4831. Το προεκπαιδευμένο SyncNet είναι σαφώς καλύτερο: ROC-AUC 0.9100 (EER 0.1819, F1 0.879) και `recall mismatched_original` 0.6580. Το AV-HuBERT υστερεί στην καθαρή εργασία συγχρονισμού, με ROC-AUC περίπου 0.73--0.74.

Η κρίσιμη παρατήρηση είναι ότι καλή ανίχνευση μη-συγχρονισμού δεν ισοδυναμεί με ανίχνευση ψεύτικου βίντεο. Όταν η βαθμολογία `sync_inconsistent_score` χρησιμοποιείται μόνη της ως ταξινομητής παραγόμενου βίντεο, είναι αντίστροφα πληροφοριακή: ROC-AUC 0.2417. Αυτό δεν σημαίνει ότι το SyncNet απέτυχε στον συγχρονισμό, σημαίνει ότι πολλά συνθετικά βίντεο είναι εσωτερικά συγχρονισμένα.



Σχήμα 6.1: Ενδεικτική σημαντικότητα ρηχών ακουστικών χαρακτηριστικών στον ακουστικό έλεγχο συγχύσεων.

6.5 Τελικό Fusion


Ο Πίνακας 6.5 αναφέρει τα αποτελέσματα σύντηξης βαθμολογιών στο υποσύνολο επικύρωσης $n = 620$ (δύο γραμμές απορρίπτονται λόγω ελλιπών οπτικοακουστικών χαρακτηριστικών). Στην παλαιότερη σύντηξη audio-concat επέρχεται κορεσμός στο ROC-AUC 1.0000, επειδή ο ηχητικός κλάδος είναι ήδη κορεσμένος στο audio-spoof manifest.

Η τρέχουσα τελική σύντηξη δεν περιλαμβάνει τη βαθμολογία της οπτικής βάσης EfficientNetB0, επειδή αυτή παράχθηκε μόνο μέσα από το σημειωματάριο και δεν υπάρχει ακόμη ως σταθερή διαδικασία CLI/checkpoint. Επομένως, η σύντηξη που αξιολογείται εδώ συνδυάζει τρεις διαθέσιμες ενδείξεις: τη βαθμολογία ηχητικής πλαστογράφησης, τη βαθμολογία ασυνέπειας συγχρονισμού και τη βαθμολογία της οπτικοακουστικής κεφαλής επιπέδου βίντεο. Ο απλός κανόνας μέγιστης βαθμολογίας πετυχαίνει ROC-AUC 0.9300, EER 0.1419 και F1 0.8281. Η logistic regression σύντηξη πετυχαίνει ελαφρώς καλύτερο λειτουργικό σημείο, με ROC-AUC 0.9307, EER 0.1338 και F1 0.8376, και γι' αυτό χρησιμοποιείται ως η κύρια εκδοχή της τελικής σύντηξης. Το μικρό MLP δεν βελτιώνει το αποτέλεσμα, φτάνοντας ROC-AUC 0.9175, EER 0.1466 και F1 0.8226.


Η οπτική βάση EfficientNetB0 αναφέρεται ξεχωριστά και δεν πρέπει να παρουσιαστεί ως είσοδος της εκπαιδευσιμής σύντηξης· βλ. `report/val_eval/final_fusion_visual_frame_una`

Πίνακας 6.3: Οπτική και οπτικοακουστική ανίχνευση ψεύτικου βίντεο στην επικύρωση. Το fixed25 κόβει κάθε κλιπ στα 25 καρέ και λειτουργεί ως έλεγχος διάρκειας. Η οπτική βάση είναι ισχυρή αλλά πιθανώς επηρεάζεται από υπογραφές ανάλυσης/codec.

Μοντέλο	Παράθυρο	ROC-AUC	EER	F1
EfficientNetB0 (οπτικά καρέ)	--	0.9853	0.0671	0.9167
SyncNet (video-level AV)	uncontrolled	0.8703	0.2018	0.7592
SyncNet (video-level AV)	fixed25	0.8468	0.2233	0.7346
AV-HuBERT (video-level AV)	uncontrolled	0.9642	0.0834	0.8972
AV-HuBERT (video-level AV)	fixed25	0.9317	0.1372	0.8337



(α) Ανάκληση/ειδικότητα ανά πηγή.



(β) Έλεγχος διάρκειας fixed25.


Σχήμα 6.2: Οπτικά και οπτικοακουστικά αποτελέσματα επιπέδου βίντεο.

6.6 Εξωτερικό stress test σύγχρονων παραγόμενων βίντεο

Ο Πίνακας 6.6 αναφέρει το εξωτερικό Higgsfield stress test σε $n = 71$ παραγόμενα βίντεο. Το SyncNet επισημαίνει 48/71 χωρίς έλεγχο παραθύρου και 43/71 με fixed25. Το AV-HuBERT επισημαίνει 59/71 και 55/71 αντίστοιχα. Με την τελική logistic-regression σύντηξη και κατώφλι 0.3702 από το MAVOS-DD, το ίδιο σύνολο πετυχαίνει ποσοστό εντοπισμού 54/71 $\approx 76.06\%$. Αυτό είναι ποσοστό εντοπισμού μόνο σε θετικά δείγματα, όχι ακρίβεια: δεν υπάρχει αντίστοιχο πραγματικό σύνολο ελέγχου, άρα δεν εκτιμάται η ειδικότητα.

Πίνακας 6.4: Κεφαλές συγχρονισμού στο validation pair manifest. Η ανάκληση `mismatched_original` είναι το πιο τίμιο διαγνωστικό, επειδή μετρά ασυμφωνία πραγματικού ήχου με στόμα άλλου πραγματικού ομιλητή και δεν κερδίζεται από TTS αποτυπώματα.


Μοντέλο	ROC-AUC	EER	F1	Ανάκληση <code>mismatched_original</code>
WavLM + BiGRU (custom)	0.8409	0.2527	0.826	0.4831
SyncNet (pretrained)	0.9100	0.1819	0.879	0.6580
AV-HuBERT (pretrained)	≈ 0.73 --0.74	--	--	--



Σχήμα 6.3: Διαγνωστική ανάκληση στον δύσκολο τύπο `mismatched_original` για τις κεφαλές συγχρονισμού.

Πίνακας 6.5: Σύντηξη βαθμολογιών στην επικύρωση. Οι γραμμές `audio-concat` της Phase 5 κορέννουνται επειδή ο ηχητικός κλάδος κορέννεται. Οι τρέχουσες γραμμές συνδυάζουν ηχητική βαθμολογία, ασυνέπεια συγχρονισμού και οπτικοακουστική βαθμολογία βίντεο σε $n = 620$ γραμμές. Η οπτική βάση EfficientNetB0 είναι σημειωματάριο-μόνο και δεν συμμετέχει στο εκπαιδευόμενο stack.


Κλάδοι	Ηχητική βάση	ROC-AUC	EER	F1
<code>audio ⊕ lips (concat)</code>	WavLM	1.0000	0.0000	--
<code>audio ⊕ lips (concat)</code>	HuBERT	1.0000	0.0000	--
<code>audio + sync + video-AV (max rule)</code>	WavLM	0.9300	0.1419	0.8281
<code>audio + sync + video-AV (LR stack)</code>	WavLM	0.9307	0.1338	0.8376
<code>audio + sync + video-AV (MLP stack)</code>	WavLM	0.9175	0.1466	0.8226



Σχήμα 6.4: Σύγκριση κανόνα μεγίστου, logistic regression και μικρού MLP στην τελική σύντηξη βαθμολογιών.

Πίνακας 6.6: Εξωτερικό stress test στο σύνολο Higgsfield ($n = 71$ παραγόμενα βίντεο, χωρίς πραγματικά αρνητικά). Οι τιμές είναι ποσοστά εντοπισμού θετικών δειγμάτων στο λειτουργικό κατώφλι κάθε κεφαλής, όχι ακρίβεια.

Βάση	Παράθυρο	Ποσοστό εντοπισμού
SyncNet	uncontrolled	48 / 71
SyncNet	fixed25	43 / 71
AV-HuBERT	uncontrolled	59 / 71
AV-HuBERT	fixed25	55 / 71
Final LR fusion	imported threshold	54 / 71



Σχήμα 6.5: Ποσοστό εντοπισμού στο εξωτερικό θετικό μόνο σύνολο Higgsfield.

Κεφάλαιο 7

Συζήτηση και Περιορισμοί

7.1 Τι σημαίνουν και τι δεν σημαίνουν οι αριθμοί

Τα σχεδόν τέλεια ηχητικά αποτελέσματα επικύρωσης δεν αποτελούν από μόνα τους απόδειξη ανθεκτικής ανίχνευσης στον πραγματικό κόσμο. Ο ακουστικός έλεγχος συγχύσεων δείχνει ότι σημαντικό μέρος του σήματος είναι ρηχό, ακουστικό και εξαρτώμενο από το κανάλι. Η κανονικοποίηση το μειώνει, αλλά δεν το αφαιρεί. Το WavLM και το HuBERT εξακολουθούν να προσφέρουν σχεδόν τέλεια διαχωρισιμότητα στην επικύρωση, γεγονός που μπορεί να εξηγηθεί με δύο αλληλεπικαλυπτόμενους τρόπους. Από τη μία, τα μοντέλα ενδέχεται να αξιοποιούν χαρακτηριστικά που σχετίζονται πράγματι με τη συνθετική παραγωγή ομιλίας. Από την άλλη, μπορεί να αξιοποιούν υπολειπόμενα σήματα παρόχου ή ηχητικού καναλιού που επιβιώνουν της κανονικοποίησης. Με τα διαθέσιμα δεδομένα, οι δύο αυτές εξηγήσεις δεν μπορούν να διαχωριστούν πλήρως.

7.2 Οπτικές και οπτικοακουστικές κεφαλές

Η οπτική βάση καρέ είναι ισχυρή στους τέσσερις παρόχους παραγόμενου βίντεο, αλλά το recall ανά πηγή διαφέρει. Η ανάκληση του LivePortrait περίπου 0.66, έναντι 1.00 για EchoMimic, MEMO και Sonic, είναι το σαφέστερο σήμα εξάρτησης από τη γεννήτρια. Επιπλέον, το ίδιο notebook δείχνει διακριτές υπογραφές ανάλυσης και codec ανά πηγή. Επομένως το EfficientNetB0 πρέπει να αναφερθεί ως ισχυρή αλλά καναλικά-συγχυμένη οπτική βάση, όχι ως καθαρή απόδειξη ότι το μοντέλο μαθαίνει ρεαλισμό προσώπου.

Η οπτικοακουστική κεφαλή βίντεο διορθώνει το λάθος σημασιολογίας που θα εισήγαγε μια αφελής ανάγνωση συγχρονισμού: τα παραγόμενα βίντεο με εγγενή ήχο παραμένουν θετικά. Ωστόσο εξακολουθεί να είναι ευάλωτη σε τεχνουργήματα γεννήτριας και σε συντομεύσεις διάρκειας. Η πτώση από το ανεξέλεγκτο παράθυρο στο fixed25 ποσοτικοποιεί τη δεύτερη επίδραση.

7.3 Η συνέπεια συγχρονισμού δεν είναι ανίχνευση deepfake

Η κεφαλή συγχρονισμού WavLM+BiGRU φαίνεται να επηρεάζεται έντονα από το ηχητικό κανάλι. Αυτό προκύπτει από το ότι αποδίδει πολύ καλά στις περιπτώσεις **generated_same_transcript** και **mismatched_generated**, όπου υπάρχει παραγόμενος ήχος, αλλά δυσκολεύεται στην περίπτωση **mismatched_original**, όπου τόσο ο ήχος όσο και το στόμα προέρχονται από πραγματικά βίντεο αλλά δεν αντιστοιχούν μεταξύ τους. Εκεί η ανάκληση είναι μόλις 0.48. Το προεκπαιδευμένο SyncNet βελτιώνει ουσιαστικά αυτό το διαγνωστικό, φτάνοντας ανάκληση 0.6580 στο **mismatched_original**, ενώ το AV-HuBERT υστερεί στην καθαρή εργασία συγχρονισμού.

Ακόμη όμως και μια ισχυρή κεφαλή συγχρονισμού δεν είναι από μόνη της ανιχνευτής ψεύτικου βίντεο. Αν ένα παραγόμενο βίντεο έχει εγγενή ήχο που είναι καλά συγχρονισμένος με την κίνηση του στόματος, τότε η κεφαλή συγχρονισμού θα το θεωρήσει συνεπές, παρότι το βίντεο παραμένει συνθετικό. Αυτός είναι ο λόγος που η διορθωμένη οπτικοακουστική κεφαλή επιπέδου βίντεο αντιμετωπίζεται ως ξεχωριστή όψη. Η τελική αξιολόγηση το δείχνει καθαρά: όταν η βαθμολογία **sync_only** χρησιμοποιείται μόνη της ως απόφαση για το αν ένα βίντεο είναι παραγόμενο, δίνει ROC-AUC 0.2417. Το αποτέλεσμα αυτό λειτουργεί ως αρνητικός έλεγχος: δείχνει ότι η ασυνέπεια συγχρονισμού και η παραγωγή/πλαστικότητα του βίντεο είναι διαφορετικές έννοιες.

7.4 Εξωτερικά παραγόμενα βίντεο και ποσοστό εντοπισμού

Το Higgsfield stress test είναι σημαντικό επειδή ελέγχει μετατόπιση κατανομής πέρα από το MAVOS-DD και τα δικά μας παραγόμενα TTS. Δεν είναι, όμως, σημείο αναφοράς ακρίβειας. Και τα 71 βίντεο είναι θετικά και δεν υπάρχει αντιστοιχισμένο πραγματικό σύνολο ελέγχου. Η αξιόπιστη ανάγνωση είναι ποσοστό εντοπισμού: η τελική logistic-regression σύντηξη, με το κατώφλι που επιλέχθηκε στο MAVOS-DD, επισημαίνει 54/71 $\approx$ 76% των κλιπ ως παραγόμενα. Χωρίς πραγματικά αρνητικά δείγματα, η ειδικότητα δεν εκτιμάται.

7.5 Η τελική σύντηξη κληρονομεί τις εισόδους της

Η σύντηξη βαθμολογιών μπορεί μόνο να συνδυάσει τις μεροληψίες των εισόδων της. Αν η ηχητική κεφαλή κορέννεται λόγω αποτυπωμάτων παρόχου, η σύντηξη θα το κληρονομήσει όταν η ηχητική βαθμολογία είναι διαθέσιμη. Στο fusion manifest, η ηχητική βαθμολογία πέφτει έντονα, υπενθυμίζοντας ότι ο κορεσμός της Phase 5 αφορά το ηχητικό manifest πλαστογράφησης, όχι απαραίτητα το τελικό βίντεο-επίπεδο πρόβλημα. Η αξία του logistic-regression stack είναι η ερμηνευσιμότητα και η βαθμονόμηση, όχι η αφαίρεση συντομεύσεων. Γι' αυτό απαγορεύεται η χρήση ταυτότητας παρόχου ή φακέλου ως χαρακτηριστικού.

7.6 Απειλές εγκυρότητας

- Το σύνολο είναι περιορισμένο και αγγλικό· τα αποτελέσματα δεν γενικεύονται αυτομάτως σε αυθαίρετα διαδικτυακά βίντεο.
- Η συνθετική ομιλία προέρχεται από λίγους παρόχους και φωνές· ο ηχητικός κλάδος μπορεί να μαθαίνει υπογραφές παρόχων.
- Τα οπτικά μοντέλα μπορεί να εκμεταλλεύονται τεχνουργήματα γεννήτριας, ανάλυσης, fps ή codec.
- Η κανονικοποίηση EBU R128 δεν αφαιρεί όλες τις ακουστικές συντομεύσεις· το υπόλοιπο κενό φαίνεται στον Πίνακα 6.2.
- Όλοι οι κύριοι αριθμοί είναι validation-only. Το test split παραμένει προστατευμένο.
- Το AV-HuBERT απαιτεί `fairseq` και συμβατότητα φόρτωσης, άρα είναι πιο εύθραυστο στην αναπαραγωγή.
- Η προεπεξεργασία SyncNet εξαρτάται από ανίχνευση προσώπου και μπορεί να αποτύχει σε δύσκολα βίντεο.
- Τα εξωτερικά θετικά μόνο σύνολα δίνουν ποσοστά εντοπισμού, όχι ακρίβεια ή ειδικότητα.
- Η οπτική βάση EfficientNetB0 δεν έχει ακόμη σταθερό CLI/checkpoint, άρα δεν συμμετέχει στην εκπαιδευσιμη σύντηξη.
- Η σύντηξη κληρονομεί όλα τα παραπάνω· δεν τα αναιρεί.

Κεφάλαιο 8

Συμπεράσματα

Η εργασία παρουσιάζει την οπτικοακουστική ανίχνευση deepfake σε περιορισμένο υποσύνολο του MAVOS-DD ως σύνολο διακριτών όψεων: ηχητική πλαστογράφηση, οπτική ανίχνευση ψεύτικου βίντεο, συνέπεια συγχρονισμού ήχου-χειλιών, οπτικοακουστική ανίχνευση ψεύτικου βίντεο και όψιμη σύντηξη βαθμολογιών. Η ισχυρότερη επιστημονική συνεισφορά δεν είναι ένας μεμονωμένος αριθμός ROC-AUC, αλλά ο διαχωρισμός ετικετών και ο έλεγχος συγχυτικών παραγόντων που επιτρέπουν να ερμηνευθούν οι αριθμοί.

Στο ηχητικό codec-matched σημείο αναφοράς, η διάκριση είναι πολύ εύκολη: WavLM και HuBERT κορέννυνται. Ο ακουστικός έλεγχος συγχύσεων και το υπόλοιπο σήμα μετά την κανονικοποίηση EBU R128 δείχνουν ότι μέρος αυτής της διαχωρισιμότητας είναι καναλικά ή παροχικά καθοδηγούμενο. Η οπτική βάση EfficientNetB0 είναι ισχυρή αλλά πιθανώς καναλικά-συγχυμένη. Η συνέπεια συγχρονισμού είναι χρήσιμο διαγνωστικό, αλλά όχι αυτόνομη ανίχνευση deepfake: ένα καλά συγχρονισμένο παραγόμενο βίντεο παραμένει θετικό παράδειγμα. Η διορθωμένη οπτικοακουστική κεφαλή βίντεο και η σύντηξη logistic regression παρέχουν συνεπή βίντεο-επίπεδη ανάγνωση, με ROC-AUC 0.9307, EER 0.1338 και F1 0.8376 στην φωνητικά ασύμπτωτη επικύρωση, αλλά χωρίς ακόμη να περιλαμβάνεται η σημειωματάριο-μόνο οπτική βαθμολογία.

Βιβλιογραφία

- [1] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [2] Sarah Barrington and Hany Farid. Single and multi-speaker cloned voice detection: From perceptual to learned features. In *IEEE International Workshop on Information Forensics and Security (WIFS)*, 2023. Representative dataset-bias / cloned-speech generalization reference.
- [3] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian, Michael Zeng, Xiangzhan Yu, and Furu Wei. Wavlm: Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 2022.
- [4] Joon Son Chung and Andrew Zisserman. Out of time: Automated lip sync in the wild. In *Asian Conference on Computer Vision (ACCV) Workshops*, 2016.
- [5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [6] Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. Hubert: Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2021.
- [7] Falko Matern, Christian Riess, and Marc Stamminger. Exploiting visual artifacts to expose deepfakes and face manipulations. In *IEEE Winter Applications of Computer Vision Workshops (WACVW)*, 2019.
- [8] MAVOS-DD dataset authors. Mavos-dd: Multilingual audio-visual open-set deepfake detection. Hugging Face dataset `unibuc-cs/MAVOS-DD`, 2024. Dataset card / repository citation.

- [9] K. R. Prajwal, Rudrabha Mukhopadhyay, Vinay P. Namboodiri, and C. V. Jawahar. A lip sync expert is all you need for speech to lip generation in the wild. In *ACM International Conference on Multimedia (ACM MM)*, 2020.
- [10] Bowen Shi, Wei-Ning Hsu, Kushal Lakhotia, and Abdelrahman Mohamed. Learning audio-visual speech representation by masked multimodal cluster prediction. In *International Conference on Learning Representations (ICLR)*, 2022.
- [11] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2019.
- [12] Zhizheng Wu, Tomi Kinnunen, Nicholas Evans, Junichi Yamagishi, Cemal Hanilçi, Md Sahidullah, and Aleksandr Sizov. Asvspoof 2015: The first automatic speaker verification spoofing and countermeasures challenge. In *INTERSPEECH*, 2015.