

Multimodal Deepfake Speech Detection using Audio and Visual Cues

Εργασία στο μάθημα "Multimodal AI"

Γραμματικόπουλος Φαίδων & Ξενάκη Μαρία

Ιούνιος 2026

Περίληψη

Η συνεχής πρόοδος των γενετικών μοντέλων τεχνητής νοημοσύνης έχει οδηγήσει στη δημιουργία ιδιαίτερα ρεαλιστικού συνθετικού οπτικοακουστικού περιεχομένου. Σύγχρονα συστήματα δημιουργίας deepfake μπορούν πλέον να παράγουν βίντεο ομιλίας υψηλής ποιότητας, στα οποία τόσο η εικόνα όσο και ο ήχος εμφανίζονται φυσικοί και δύσκολα διαχωρίσιμοι από πραγματικά δεδομένα. Η εξέλιξη αυτή δημιουργεί σημαντικές προκλήσεις σε ζητήματα ασφάλειας, παραπληροφόρησης, προστασίας προσωπικών δεδομένων και ψηφιακής ταυτότητας.

Στην παρούσα εργασία μελετάται το πρόβλημα της ανίχνευσης συνθετικών βίντεο ομιλίας μέσω πολυτροπικής ανάλυσης, η οποία αξιοποιεί πληροφορία τόσο από το οπτικό όσο και από το ηχητικό κανάλι. Για την οπτική πληροφορία χρησιμοποιούνται χαρακτηριστικά που εξάγονται από προεκπαιδευμένο μοντέλο ResNet50, καθώς και χαρακτηριστικά κίνησης της περιοχής του στόματος μέσω MediaPipe Face Mesh. Για την ηχητική πληροφορία αξιοποιούνται βαθιές αναπαραστάσεις που εξάγονται από προεκπαιδευμένα μοντέλα επεξεργασίας ομιλίας. Στη συνέχεια εξετάζονται διαφορετικές στρατηγικές συνδυασμού (fusion) των δύο τροπικότητων με σκοπό τη βελτίωση της συνολικής απόδοσης.

Για την αξιολόγηση των προτεινόμενων προσεγγίσεων χρησιμοποιείται το σύνολο δεδομένων MAVOS-DD, το οποίο περιλαμβάνει πραγματικά και συνθετικά βίντεο που έχουν δημιουργηθεί από διαφορετικές γεννήτριες deepfake. Εξετάζονται πολλαπλά μοντέλα ταξινόμησης για κάθε τροπικότητα, καθώς και τεχνικές σύντηξης των δύο πηγών πληροφορίας.

Ιδιαίτερη έμφαση δίνεται στην ικανότητα γενίκευσης των μοντέλων σε άγνωστες μεθόδους παραγωγής deepfake μέσω ειδικών πειραμάτων open-generator evaluation. Τα αποτελέσματα της μελέτης αναμένεται να αναδείξουν τα πλεονεκτήματα και τους περιορισμούς κάθε τροπικότητας, καθώς και τα οφέλη της πολυτροπικής σύντηξης στην ανίχνευση συνθετικού οπτικοακουστικού περιεχομένου.

Εισαγωγή

Η δημιουργία συνθετικού περιεχομένου μέσω τεχνητής νοημοσύνης αποτελεί μία από τις σημαντικότερες εξελίξεις των τελευταίων ετών στον χώρο της μηχανικής μάθησης. Η ανάπτυξη γενετικών μοντέλων υψηλής ποιότητας έχει επιτρέψει την παραγωγή εικόνων, βίντεο και ηχητικών αποσπασμάτων που παρουσιάζουν εξαιρετικά υψηλό βαθμό ρεαλισμού.

Μία από τις πλέον διαδεδομένες εφαρμογές των γενετικών μοντέλων είναι τα deepfakes. Τα συστήματα αυτά μπορούν να δημιουργήσουν βίντεο στα οποία ένα άτομο φαίνεται να μιλά, να κινείται ή να εκφράζεται με τρόπο που δεν συνέβη ποτέ στην πραγματικότητα. Παράλληλα, οι σύγχρονες τεχνικές συνθετικής ομιλίας επιτρέπουν την παραγωγή φωνής η οποία προσομοιάζει με μεγάλη ακρίβεια τη φωνή πραγματικών ανθρώπων.

Παρότι οι τεχνολογίες αυτές προσφέρουν σημαντικές δυνατότητες σε τομείς όπως η ψυχαγωγία, η εκπαίδευση, η παραγωγή ψηφιακού περιεχομένου και η προσβασιμότητα, ταυτόχρονα δημιουργούν σοβαρούς κινδύνους. Η χρήση deepfakes για παραπληροφόρηση, πλαστοπροσωπία, οικονομικές απάτες ή πολιτική χειραγώγηση έχει αναδειχθεί σε σημαντικό πρόβλημα για την κοινωνία και την επιστημονική κοινότητα.

Η ανίχνευση deepfakes αποτελεί πλέον ενεργό ερευνητικό πεδίο. Οι περισσότερες υπάρχουσες προσεγγίσεις επικεντρώνονται είτε αποκλειστικά στην εικόνα είτε αποκλειστικά στον ήχο. Ωστόσο, καθώς τα σύγχρονα γενετικά μοντέλα βελτιώνονται συνεχώς, οι ενδείξεις παραποίησης σε κάθε μεμονωμένη τροπικότητα γίνονται ολοένα πιο δυσδιάκριτες.

Για τον λόγο αυτό, η πολυτροπική ανάλυση αποτελεί μία ιδιαίτερα υποσχόμενη κατεύθυνση έρευνας. Η βασική ιδέα είναι ότι εικόνα και ήχος παρέχουν συμπληρωματικές πληροφορίες σχετικά με την αυθεντικότητα ενός βίντεο. Ένα συνθετικό βίντεο ενδέχεται να παρουσιάζει οπτικές ασυνέπειες στις κινήσεις του προσώπου, μη φυσιολογική δυναμική των χειλιών ή χαρακτηριστικά συνθετικής ομιλίας τα οποία δεν είναι εμφανή όταν εξετάζεται μόνο μία από τις δύο τροπικότητες.

Στόχος της παρούσας εργασίας είναι η ανάπτυξη και αξιολόγηση ενός πολυτροπικού συστήματος ανίχνευσης deepfake για βίντεο ομιλίας. Συγκεκριμένα, μελετώνται ανεξάρτητα το οπτικό και το ακουστικό υποσύστημα, ενώ στη συνέχεια εξετάζεται η σύντηξη των δύο πηγών πληροφορίας.

Επιπλέον, διερευνάται η ικανότητα γενίκευσης των μοντέλων σε βίντεο που έχουν παραχθεί από διαφορετικές γεννήτριες deepfake, προσομοιώνοντας πιο ρεαλιστικά σενάρια χρήσης.

Σχετική Βιβλιογραφία

Η ανίχνευση deepfakes έχει εξελιχθεί σε ένα από τα πλέον ενεργά πεδία έρευνας στη μηχανική μάθηση και την υπολογιστική όραση. Η συνεχής βελτίωση των γενετικών μοντέλων έχει καταστήσει ολοένα δυσκολότερο τον εντοπισμό συνθετικού περιεχομένου, οδηγώντας στην ανάπτυξη εξειδικευμένων τεχνικών ανίχνευσης. Οι προτεινόμενες μέθοδοι μπορούν να ταξινομηθούν σε τρεις βασικές κατηγορίες: οπτικές μέθοδοι, ακουστικές μέθοδοι και πολυτροπικές μέθοδοι.

Οπτική Ανίχνευση Deepfake

Οι πρώτες προσπάθειες ανίχνευσης deepfake επικεντρώθηκαν κυρίως στην οπτική πληροφορία. Οι αρχικές γενιές συνθετικών βίντεο παρουσίαζαν εμφανείς ατέλειες, όπως μη φυσιολογικές κινήσεις των ματιών, ασυνέπειες στον φωτισμό, παραμορφώσεις του προσώπου και σφάλματα στην περιοχή του στόματος. Οι ατέλειες αυτές μπορούσαν να εντοπιστούν μέσω κλασικών τεχνικών επεξεργασίας εικόνας ή μέσω συνελκτικών νευρωνικών δικτύων.

Με την ευρεία χρήση των Convolutional Neural Networks (CNNs), η ανίχνευση deepfake μετατοπίστηκε προς την αυτόματη εξαγωγή χαρακτηριστικών από τα καρέ των βίντεο. Αρχιτεκτονικές όπως οι VGG, ResNet και EfficientNet χρησιμοποιήθηκαν ως εξαγωγείς χαρακτηριστικών ή εκπαιδευτήκαν απευθείας για το πρόβλημα της δυναμικής ταξινόμησης μεταξύ πραγματικών και συνθετικών δειγμάτων.

Ωστόσο, η ανάλυση μεμονωμένων καρέ παρουσιάζει έναν σημαντικό περιορισμό: αγνοεί τη χρονική πληροφορία. Για τον λόγο αυτό προτάθηκαν προσεγγίσεις που συνδυάζουν CNNs με χρονικά μοντέλα, όπως τα Long Short-Term Memory (LSTM) και Gated Recurrent Unit (GRU) δίκτυα. Οι μέθοδοι αυτές επιτρέπουν την αξιοποίηση της χρονικής δυναμικής των εκφράσεων του προσώπου, των κινήσεων των χειλιών και της συνολικής συμπεριφοράς του ομιλητή κατά τη διάρκεια του βίντεο.

Πιο πρόσφατες εργασίες αξιοποιούν Vision Transformers (ViTs) και αρχιτεκτονικές attention, οι οποίες έχουν δείξει ιδιαίτερα υψηλές επιδόσεις σε μεγάλης κλίμακας σύνολα δεδομένων deepfake. Παρόλα αυτά, τα μοντέλα αυτά απαιτούν σημαντικά μεγαλύτερους υπολογιστικούς πόρους και μεγάλο όγκο δεδομένων εκπαίδευσης.

Ακουστική Ανίχνευση Συνθετικής Ομιλίας

Η παράλληλη ανάπτυξη τεχνολογιών σύνθεσης ομιλίας έχει δημιουργήσει την ανάγκη ανίχνευσης συνθετικών ηχητικών αποσπασμάτων. Τα σύγχρονα συστήματα text-to-speech και voice cloning μπορούν να παράγουν ομιλία ιδιαίτερα υψηλής ποιότητας, η οποία συχνά είναι δύσκολο να διακριθεί από ανθρώπινη ομιλία.

Οι πρώτες προσεγγίσεις βασίστηκαν σε χειροποίητα ακουστικά χαρακτηριστικά, όπως οι συντελεστές Mel-Frequency Cepstral Coefficients (MFCCs), τα χαρακτηριστικά φασματικής ενέργειας και διάφορες μορφές φασματικής ανάλυσης. Τα χαρακτηριστικά αυτά χρησιμοποιήθηκαν σε συνδυασμό με ταξινομητές όπως οι Support Vector Machines και οι Random Forests.

Η εξέλιξη των τεχνικών βαθιάς μάθησης οδήγησε στη χρήση συνελκτικών και αναδρομικών νευρωνικών δικτύων για την αυτόματη εξαγωγή ακουστικών αναπαραστάσεων. Σημαντική πρόοδος σημειώθηκε με την εμφάνιση προεκπαιδευμένων μοντέλων επεξεργασίας ομιλίας, όπως τα wav2vec2, HuBERT και WavLM, τα οποία μαθαίνουν πλούσιες αναπαραστάσεις απευθείας από το ηχητικό σήμα.

Ιδιαίτερα στον τομέα της ανίχνευσης συνθετικής ομιλίας, τα προεκπαιδευμένα μοντέλα έχουν επιτύχει εξαιρετικά αποτελέσματα σε διαγωνισμούς και benchmarks όπως το ASVspoof. Η ικανότητά

τους να συλλαμβάνουν λεπτές ακουστικές ασυνέπειες τα καθιστά ιδιαίτερα κατάλληλα για τον εντοπισμό σύγχρονων τεχνικών σύνθεσης φωνής.

Πολυτροπική Ανίχνευση Deepfake

Παρά τις σημαντικές επιδόσεις των μονοτροπικών συστημάτων, η αποκλειστική χρήση εικόνας ή ήχου παρουσιάζει περιορισμούς. Καθώς τα σύγχρονα γενετικά μοντέλα βελτιώνονται, τα σφάλματα που εμφανίζονται σε μία μόνο τροπικότητα γίνονται ολοένα πιο δυσδιάκριτα.

Για τον λόγο αυτό η ερευνητική κοινότητα έχει στραφεί προς πολυτροπικές προσεγγίσεις, οι οποίες συνδυάζουν πληροφορία από εικόνα και ήχο. Η βασική υπόθεση είναι ότι οι δύο τροπικότητες περιέχουν συμπληρωματικές ενδείξεις σχετικά με την αυθεντικότητα ενός βίντεο.

Στα βίντεο ομιλίας, για παράδειγμα, είναι πιθανό η οπτική πληροφορία να φαίνεται απολύτως ρεαλιστική, ενώ η παραγόμενη ομιλία να παρουσιάζει ακουστικές ανωμαλίες. Αντίστοιχα, η ομιλία μπορεί να ακούγεται φυσιολογική αλλά να υπάρχουν ασυνέπειες στον συγχρονισμό μεταξύ ήχου και κινήσεων των χειλιών.

Οι πολυτροπικές προσεγγίσεις διακρίνονται συνήθως σε τρεις κατηγορίες. Η πρώτη αφορά τη σύντηξη σε επίπεδο χαρακτηριστικών (feature-level fusion), όπου οι αναπαραστάσεις των δύο τροπικοτήτων συνενώνονται πριν από την ταξινόμηση. Η δεύτερη αφορά τη σύντηξη σε επίπεδο αποφάσεων (late fusion), όπου συνδυάζονται οι προβλέψεις ανεξάρτητων μοντέλων εικόνας και ήχου. Η τρίτη κατηγορία περιλαμβάνει πλήρως ενοποιημένες αρχιτεκτονικές που εκπαιδεύονται ταυτόχρονα και στις δύο τροπικότητες.

Στην παρούσα εργασία ακολουθείται πολυτροπική προσέγγιση, όπου αναπτύσσονται ανεξάρτητα οπτικό και ακουστικό υποσύστημα και στη συνέχεια εξετάζεται η σύντηξη των δύο πηγών πληροφορίας. Η επιλογή αυτή επιτρέπει την ανεξάρτητη αξιολόγηση κάθε τροπικότητας, καθώς και τη μελέτη της συνεισφοράς τους στο τελικό σύστημα ανίχνευσης deepfake.

Δεδομένα και Μεθοδολογία

Σύνολο Δεδομένων MAVOS-DD

Για την αξιολόγηση των προτεινόμενων μεθόδων χρησιμοποιήθηκε το σύνολο δεδομένων MAVOS-DD (Multimodal Audio-Visual Open-Set Deepfake Detection Dataset). Το συγκεκριμένο dataset δημιουργήθηκε με στόχο την ανάπτυξη και αξιολόγηση συστημάτων ανίχνευσης συνθετικού οπτικο-ακουστικού περιεχομένου και περιλαμβάνει τόσο πραγματικά όσο και συνθετικά βίντεο ομιλίας.

Τα βίντεο του συνόλου δεδομένων ανήκουν σε τρεις βασικές κατηγορίες:

- **Real:** αυθεντικά βίντεο χωρίς επεξεργασία.
- **EchoMimic:** συνθετικά βίντεο που δημιουργήθηκαν μέσω του μοντέλου EchoMimic.
- **MEMO:** συνθετικά βίντεο που δημιουργήθηκαν μέσω του μοντέλου MEMO.

Στην παρούσα εργασία αντιμετωπίζουμε το πρόβλημα ως δυαδική ταξινόμηση, όπου τα πραγματικά βίντεο αντιστοιχούν στην κλάση 0 και τα συνθετικά βίντεο στην κλάση 1.

Το σύνολο δεδομένων περιλαμβάνει περίπου 1000 δείγματα, εκ των οποίων περίπου 500 είναι πραγματικά και 500 συνθετικά. Κάθε δείγμα περιέχει τόσο οπτική όσο και ακουστική πληροφορία, γεγονός που επιτρέπει την ανάπτυξη πολυτροπικών συστημάτων ανίχνευσης.

Γενική Αρχιτεκτονική Συστήματος

Η προτεινόμενη προσέγγιση αποτελείται από 3 διακριτά υποσυστήματα:

1. Visual Branch

2. Audio Branch
3. Fusion Module

Τα δύο πρώτα υποσυστήματα λειτουργούν ανεξάρτητα και παράγουν προβλέψεις ή αναπαραστάσεις χαρακτηριστικών για κάθε βίντεο. Στη συνέχεια, οι πληροφορίες αυτές συνδυάζονται μέσω μηχανισμού σύντηξης, προκειμένου να ληφθεί η τελική απόφαση σχετικά με την αυθεντικότητα του δείγματος.

Visual Branch

Frame Sampling

Η επεξεργασία όλων των καρέ ενός βίντεο οδηγεί σε ιδιαίτερα αυξημένο υπολογιστικό κόστος. Για τον λόγο αυτό εφαρμόστηκε ομοιόμορφη χρονική δειγματοληψία (uniform temporal sampling).

Από κάθε βίντεο επιλέχθηκαν 20 καρέ καταναμημένα ισομερώς σε όλη τη διάρκειά του. Η επιλογή αυτή επιτρέπει την κάλυψη ολόκληρης της χρονικής εξέλιξης του βίντεο διατηρώντας παράλληλα λογικές απαιτήσεις σε χρόνο και μνήμη.

Feature Extraction με ResNet50

Για την εξαγωγή οπτικών χαρακτηριστικών χρησιμοποιήθηκε το προεκπαιδευμένο συνελικτικό νευρωνικό δίκτυο ResNet50.

Το μοντέλο αρχικοποιήθηκε με βάρη εκπαιδευμένα στο ImageNet και χρησιμοποιήθηκε αποκλειστικά ως εξαγωγέας χαρακτηριστικών. Για κάθε επιλεγμένο καρέ πραγματοποιήθηκε:

1. Μετατροπή σε μορφή RGB,
2. Αλλαγή μεγέθους σε 224×224 pixels,
3. Κανονικοποίηση σύμφωνα με τα στατιστικά του ImageNet, και
4. Εξαγωγή embedding 2048 διαστάσεων.

Στα μοντέλα Logistic Regression και MLP εφαρμόστηκε mean pooling των embeddings όλων των frames ώστε να παραχθεί μία ενιαία αναπαράσταση ανά βίντεο.

Χρονική Μοντελοποίηση μέσω LSTM

Προκειμένου να αξιοποιηθεί η χρονική πληροφορία των βίντεο, εξετάστηκε και προσέγγιση βασισμένη σε Long Short-Term Memory (LSTM).

Σε αυτή την περίπτωση διατηρείται ολόκληρη η ακολουθία των embeddings των 20 frames. Κάθε embedding 2048 διαστάσεων προβάλλεται αρχικά σε χώρο 256 διαστάσεων και στη συνέχεια εισάγεται στο LSTM. Η τελική κρυφή κατάσταση χρησιμοποιείται για την παραγωγή της πρόβλεψης.

Η συγκεκριμένη προσέγγιση επιτρέπει την αξιοποίηση πληροφοριών σχετικών με τη χρονική δυναμική των εκφράσεων και των κινήσεων του προσώπου.

Χαρακτηριστικά Κίνησης Χειλιών

Πέρα από τα βαθιά χαρακτηριστικά που εξάγονται μέσω του ResNet50, εξετάστηκε και μία περισσότερο ερμηνεύσιμη προσέγγιση βασισμένη στη γεωμετρία και την κίνηση της περιοχής του στόματος.

Χρησιμοποιώντας το MediaPipe Face Mesh εντοπίστηκαν σημεία αναφοράς της περιοχής των χειλιών. Από τα σημεία αυτά υπολογίστηκαν χαρακτηριστικά όπως:

- πλάτος στόματος,
- ύψος στόματος,
- λόγος ύψους προς πλάτος,
- προσεγγιστική επιφάνεια στόματος,
- ταχύτητα μετακίνησης του κέντρου του στόματος.

Για κάθε χαρακτηριστικό υπολογίστηκαν στατιστικά μεγέθη σε επίπεδο βίντεο και χρησιμοποιήθηκαν ως είσοδος σε ταξινομητή Random Forest.

Audio Branch

Για την ανάλυση της ακουστικής πληροφορίας αναπτύχθηκε ανεξάρτητο υποσύστημα ανίχνευσης συνθετικής ομιλίας.

Αρχικά εξάγεται το ηχητικό σήμα από κάθε βίντεο και ακολουθεί κατάλληλη προεπεξεργασία. Στη συνέχεια χρησιμοποιείται προεκπαιδευμένο μοντέλο επεξεργασίας ομιλίας για την εξαγωγή αναπαραστάσεων υψηλού επιπέδου.

[PLACEHOLDER: Περιγραφή του audio encoder.]

[PLACEHOLDER: Περιγραφή του audio classifier.]

[PLACEHOLDER: Υπερπαράμετροι εκπαίδευσης.]

Fusion Module

Μετά την ανεξάρτητη επεξεργασία εικόνας και ήχου, οι πληροφορίες των δύο τροπικοτήτων συνδυάζονται μέσω μηχανισμού fusion.

Στην παρούσα εργασία εξετάζεται προσέγγιση late fusion, κατά την οποία κάθε υποσύστημα παράγει ανεξάρτητη πιθανότητα ότι το δείγμα είναι συνθετικό. Οι πιθανότητες αυτές συνδυάζονται προκειμένου να παραχθεί η τελική πρόβλεψη.

Η επιλογή της late fusion προσέγγισης επιτρέπει:

- ανεξάρτητη ανάπτυξη των δύο υποσυστημάτων,
- ευκολότερη ερμηνεία των αποτελεσμάτων,
- μεγαλύτερη ευελιξία σε περιπτώσεις όπου μία τροπικότητα δεν είναι διαθέσιμη.

[PLACEHOLDER: Τελική εξίσωση ή μέθοδος σύντηξης.]

[PLACEHOLDER: Τελικός fusion classifier.]

Πειραματική Διαδικασία

Υπολογιστικό Περιβάλλον

Η υλοποίηση των πειραμάτων πραγματοποιήθηκε στη γλώσσα προγραμματισμού Python αξιοποιώντας τις βιβλιοθήκες PyTorch, Torchvision, Scikit-Learn, OpenCV και MediaPipe.

Για την επιτάχυνση της εξαγωγής χαρακτηριστικών από τα βίντεο χρησιμοποιήθηκε GPU όπου ήταν διαθέσιμη, ενώ τα υπόλοιπα στάδια επεξεργασίας και αξιολόγησης εκτελέστηκαν μέσω της βιβλιοθήκης Scikit-Learn.

Η εξαγωγή χαρακτηριστικών από τα βίντεο πραγματοποιήθηκε εκτός σύνδεσης και τα παραγόμενα embeddings αποθηκεύτηκαν σε αρχεία CSV ώστε να επιτρέπεται η επαναληπτική εκπαίδευση διαφορετικών ταξινομητών χωρίς την ανάγκη επανεξαγωγής χαρακτηριστικών.

Πρωτόκολλο Αξιολόγησης

Αρχικά εφαρμόστηκε τυχαίος διαχωρισμός των δεδομένων σε σύνολο εκπαίδευσης και σύνολο αξιολόγησης. Συγκεκριμένα χρησιμοποιήθηκε αναλογία 70% Εκπαίδευση & 30% Αξιολόγηση με stratified sampling, ώστε να διατηρείται η αναλογία πραγματικών και συνθετικών δειγμάτων στα δύο σύνολα.

Όλα τα μοντέλα αξιολογήθηκαν χρησιμοποιώντας ακριβώς τον ίδιο διαχωρισμό δεδομένων προκειμένου να εξασφαλιστεί δίκαιη σύγκριση.

Ρυθμίσεις Visual Branch

Για κάθε βίντεο επιλέχθηκαν 20 frames μέσω ομοιόμορφης χρονικής δειγματοληψίας. Τα frames μετατράπηκαν σε embeddings 2048 διαστάσεων μέσω του προεκπαιδευμένου ResNet50. Για τα μοντέλα Logistic Regression και MLP εφαρμόστηκε mean pooling στα embeddings όλων των frames, παράγοντας ένα μοναδικό διάνυσμα χαρακτηριστικών ανά βίντεο. Στην περίπτωση του LSTM διατηρήθηκε ολόκληρη η ακολουθία των 20 embeddings ώστε να αξιοποιηθεί η χρονική πληροφορία.

Logistic Regression Για το μοντέλο Logistic Regression χρησιμοποιήθηκαν τα ακόλουθα χαρακτηριστικά:

- StandardScaler
- Μέγιστος αριθμός επαναλήψεων: 1000

MLP Η αρχιτεκτονική του MLP αποτελείται από δύο κρυφά επίπεδα: $2048 \rightarrow 256 \rightarrow 64 \rightarrow 1$ με συνάρτηση ενεργοποίησης ReLU. Οι βασικές υπερπαραμέτροι ήταν:

- Hidden Layers: (256, 64)
- Activation: ReLU
- Max Iterations: 300

LSTM Για την αξιοποίηση της χρονικής πληροφορίας χρησιμοποιήθηκε δίκτυο LSTM. Αρχικά κάθε embedding των 2048 διαστάσεων προβάλλεται σε χώρο 256 διαστάσεων μέσω γραμμικού επιπέδου. Στη συνέχεια η ακολουθία εισάγεται στο LSTM και η τελική κρυφή κατάσταση χρησιμοποιείται για τη δυαδική ταξινόμηση. Οι βασικές παράμετροι του μοντέλου ήταν:

- Input Projection: $2048 \rightarrow 256$
- Hidden Size: [PLACEHOLDER]
- Number of Layers: [PLACEHOLDER]
- Batch Size: [PLACEHOLDER]
- Epochs: [PLACEHOLDER]

Lip Features + Random Forest Για το Random Forest χρησιμοποιήθηκαν τα γεωμετρικά χαρακτηριστικά της περιοχής του στόματος που εξήχθησαν μέσω του MediaPipe Face Mesh. Οι βασικές παράμετροι του ταξινομητή ήταν:

- Number of Trees: 200
- Class Weight: Balanced

Ρυθμίσεις Ηχητικού Υποσυστήματος

[PLACEHOLDER: Περιγραφή audio preprocessing.]

[PLACEHOLDER: Περιγραφή wav2vec2 ή άλλου encoder.]

[PLACEHOLDER: Hyperparameters audio classifier.]

Fusion

Μετά την ανεξάρτητη εκπαίδευση των οπτικών και ηχητικών μοντέλων εφαρμόστηκε μηχανισμός σύντηξης των δύο τροποικοτήτων. Η σύντηξη πραγματοποιήθηκε σε επίπεδο προβλέψεων (late fusion).

[PLACEHOLDER: Μέθοδος συνδυασμού πιθανοτήτων.]

[PLACEHOLDER: Fusion classifier.]

Αξιολόγηση Γενίκευσης σε Άγνωστους Generators

Πέρα από τον τυχαίο διαχωρισμό των δεδομένων, πραγματοποιήθηκε και αξιολόγηση γενίκευσης μεταξύ διαφορετικών γεννητριών deepfake.

Στο πρώτο πείραμα το μοντέλο εκπαιδεύτηκε χρησιμοποιώντας πραγματικά βίντεο και δείγματα EchoMimic, ενώ αξιολογήθηκε σε πραγματικά βίντεο και δείγματα MEMO.

Στο δεύτερο πείραμα ακολουθήθηκε η αντίστροφη διαδικασία.

Η αξιολόγηση αυτή επιτρέπει τη μελέτη της ικανότητας γενίκευσης των μοντέλων σε άγνωστες μεθόδους παραγωγής deepfake και προσομοιώνει πιο ρεαλιστικά σενάρια χρήσης.

Ανάλυση Επίδρασης Αριθμού frames

Προκειμένου να διερευνηθεί η επίδραση της χρονικής δειγματοληψίας στην απόδοση του συστήματος, πραγματοποιήθηκε επιπλέον πείραμα με διαφορετικό αριθμό frame ανά βίντεο. Συγκεκριμένα εξετάστηκαν οι ακόλουθες τιμές:

- 10 frames
- 20 frames
- 40 frames

Η ανάλυση αυτή επιτρέπει τη μελέτη του συμβιβασμού μεταξύ υπολογιστικού κόστους και απόδοσης ταξινόμησης.

Μετρικές Αξιολόγησης

Η απόδοση των μοντέλων αξιολογήθηκε μέσω των ακόλουθων μετρικών: Accuracy, Precision, Recall, F1-score και ROC-AUC.

Η Accuracy εκφράζει το ποσοστό σωστών προβλέψεων, ενώ η Precision και η Recall αξιολογούν την ποιότητα και την πληρότητα των θετικών προβλέψεων αντίστοιχα.

Η F1-score χρησιμοποιήθηκε ως βασική μετρική σύγκρισης των μοντέλων, καθώς συνδυάζει πληροφορία τόσο από την Precision όσο και από την Recall. Παράλληλα, η ROC-AUC αξιολογεί την ικανότητα διάκρισης μεταξύ πραγματικών και συνθετικών δειγμάτων ανεξάρτητα από το κατώφλι απόφασης.

Αποτελέσματα

Στην ενότητα αυτή παρουσιάζονται τα αποτελέσματα της αξιολόγησης του προτεινόμενου συστήματος ανίχνευσης deepfake. Αρχικά εξετάζεται η απόδοση των διαφορετικών οπτικών μοντέλων στο βασικό πρωτόκολλο αξιολόγησης. Στη συνέχεια πραγματοποιείται αξιολόγηση της δυνατότητας γενίκευσης των μοντέλων σε διαφορετικούς generators (Open Generator Evaluation), ενώ τέλος αναλύεται η ποιότητα των εξαγόμενων χαρακτηριστικών μέσω οπτικοποίησης του χώρου χαρακτηριστικών και διασταυρούμενης επικύρωσης.

0.1 Αξιολόγηση Οπτικών Μοντέλων

Η πρώτη ομάδα πειραμάτων επικεντρώθηκε αποκλειστικά στην οπτική πληροφορία. Για κάθε βίντεο επιλέχθηκαν αντιπροσωπευτικά καρέ, από τα οποία εξήχθησαν βαθιές αναπαραστάσεις μέσω του προεκπαιδευμένου ResNet50. Οι αναπαραστάσεις αυτές χρησιμοποιήθηκαν ως είσοδος σε διαφορετικούς ταξινομητές μηχανικής μάθησης. Παράλληλα, αξιολογήθηκε μία δεύτερη προσέγγιση βασισμένη αποκλειστικά στη γεωμετρία και την κίνηση της περιοχής του στόματος μέσω χαρακτηριστικών που εξήχθησαν από το MediaPipe Face Mesh.

Η αξιολόγηση πραγματοποιήθηκε με τυχαίο διαχωρισμό των δεδομένων σε σύνολο εκπαίδευσης (70%) και αξιολόγησης (30%), διατηρώντας την αναλογία πραγματικών και συνθετικών βίντεο (stratified split).

Ο Πίνακας 1 παρουσιάζει τα αποτελέσματα των τεσσάρων μοντέλων που εξετάστηκαν.

Πίνακας 1: Σύγκριση των οπτικών μοντέλων.

Μοντέλο	Accuracy	F1-score	ROC-AUC
Logistic Regression (ResNet50)	0.9967	0.9967	1.0000
MLP (ResNet50)	0.9967	0.9967	1.0000
LSTM (ResNet50)	0.9967	0.9967	1.0000
Logistic Regression (Lip Features)	0.9885	0.9900	0.9992

Τα αποτελέσματα δείχνουν ότι οι βαθιές αναπαραστάσεις που εξάγονται από το προεκπαιδευμένο ResNet50 διαθέτουν ιδιαίτερα υψηλή διακριτική ικανότητα για τον διαχωρισμό πραγματικών και συνθετικών βίντεο. Τόσο η Logistic Regression όσο και τα νευρωνικά μοντέλα MLP και LSTM πέτυχαν σχεδόν ταυτόσημη απόδοση, με Accuracy και F1-score που προσεγγίζουν το 100%.

Το γεγονός ότι ακόμη και ένας γραμμικός ταξινομητής, όπως η Logistic Regression, επιτυγχάνει τόσο υψηλή απόδοση υποδηλώνει ότι ο χώρος χαρακτηριστικών που παράγεται από το ResNet50 είναι ήδη σε μεγάλο βαθμό γραμμικά διαχωρίσιμος. Αντίστοιχα, η χρήση πιο σύνθετων μοντέλων, όπως το MLP και το LSTM, δεν οδήγησε σε ουσιαστική βελτίωση, γεγονός που υποδηλώνει ότι το μεγαλύτερο μέρος της διακριτικής πληροφορίας βρίσκεται ήδη στα εξαγόμενα embeddings.

Η εναλλακτική προσέγγιση που βασίζεται αποκλειστικά σε χαρακτηριστικά της περιοχής του στόματος παρουσιάζει μικρότερη απόδοση σε σχέση με τις βαθιές αναπαραστάσεις του ResNet50. Ωστόσο, αποτελεί μία περισσότερο ερμηνεύσιμη (interpretable) μέθοδο, καθώς αξιοποιεί αποκλειστικά γεωμετρικά χαρακτηριστικά της κίνησης των χειλιών και μπορεί να λειτουργήσει συμπληρωματικά σε πολυτροπικά συστήματα.

Αξιολόγηση Γενίκευσης μεταξύ Διαφορετικών Generators

Η υψηλή απόδοση ενός μοντέλου στο κλασικό train/test split δεν συνεπάγεται απαραίτητα και ικανότητα γενίκευσης σε άγνωστες τεχνικές δημιουργίας deepfake. Για τον λόγο αυτό πραγματοποιήθηκε επιπλέον αξιολόγηση μεταξύ διαφορετικών generators (Open Generator Evaluation).

Συγκεκριμένα, εξετάστηκαν δύο ανεξάρτητα σενάρια:

1. Εκπαίδευση σε πραγματικά βίντεο και δείγματα EchoMimic, με αξιολόγηση σε πραγματικά βίντεο και δείγματα MEMO.
2. Εκπαίδευση σε πραγματικά βίντεο και δείγματα MEMO, με αξιολόγηση σε πραγματικά βίντεο και δείγματα EchoMimic.

Με τον τρόπο αυτό αξιολογείται η ικανότητα των μοντέλων να αναγνωρίζουν συνθετικό περιεχόμενο που έχει παραχθεί από διαφορετική τεχνική δημιουργίας από εκείνη που χρησιμοποιήθηκε κατά την εκπαίδευση.

Τα αποτελέσματα παρουσιάζονται στον Πίνακα 2.

Πίνακας 2: Αποτελέσματα Open Generator Evaluation.

Πείραμα	Μοντέλο	Accuracy	F1-score
EchoMimic → MEMO	Logistic Regression	0.9987	0.9980
EchoMimic → MEMO	MLP	0.9973	0.9960
MEMO → EchoMimic	Logistic Regression	1.0000	1.0000
MEMO → EchoMimic	MLP	0.9987	0.9980

Παρατηρείται ότι και στα δύο πειραματικά σενάρια τα μοντέλα διατηρούν εξαιρετικά υψηλή απόδοση. Η Logistic Regression επιτυγχάνει Accuracy μεγαλύτερο από 99.8% ακόμη και όταν αξιολογείται σε δείγματα διαφορετικού generator, ενώ το MLP παρουσιάζει αντίστοιχα πολύ μικρή μόνο μείωση της απόδοσης.

Το εύρημα αυτό είναι ιδιαίτερα σημαντικό, καθώς δείχνει ότι τα χαρακτηριστικά που εξάγονται από το ResNet50 δεν κωδικοποιούν αποκλειστικά ιδιαιτερότητες ενός συγκεκριμένου generator, αλλά περιγράφουν γενικότερα οπτικά μοτίβα που χαρακτηρίζουν τα συνθετικά βίντεο.

Παρόλα αυτά, τα αποτελέσματα αυτά πρέπει να ερμηνεύονται με προσοχή. Η αξιολόγηση πραγματοποιήθηκε σε επίπεδο βίντεο και όχι σε επίπεδο διαφορετικών ομιλητών (subject-disjoint evaluation), καθώς το MAVOS-DD δεν παρέχει πληροφορίες ταυτότητας των προσώπων. Συνεπώς, το συγκεκριμένο πείραμα αξιολογεί τη δυνατότητα γενίκευσης μεταξύ διαφορετικών generators και όχι τη γενίκευση σε άγνωστα πρόσωπα.


Συνολικά, τα αποτελέσματα του Open Generator Evaluation υποδηλώνουν ότι η προτεινόμενη οπτική προσέγγιση εμφανίζει ιδιαίτερα υψηλή ανθεκτικότητα απέναντι σε διαφορετικές τεχνικές δημιουργίας deepfake, γεγονός που αποτελεί σημαντική προϋπόθεση για την ανάπτυξη πρακτικών συστημάτων ανίχνευσης σε πραγματικές συνθήκες.

Ανάλυση του Χώρου Χαρακτηριστικών

Προκειμένου να διερευνηθεί η ποιότητα των χαρακτηριστικών που εξάγονται από το προεκπαιδευμένο ResNet50, πραγματοποιήθηκε οπτικοποίηση των embeddings μέσω των τεχνικών Principal Component Analysis (PCA) και t-distributed Stochastic Neighbor Embedding (t-SNE).

Η PCA αποτελεί μία γραμμική μέθοδο μείωσης διαστάσεων, η οποία προβάλλει τα δεδομένα στις διευθύνσεις με τη μεγαλύτερη διακύμανση, επιτρέποντας την οπτική διερεύνηση της δομής του χώρου χαρακτηριστικών. Αντίθετα, η t-SNE είναι μία μη γραμμική μέθοδος που διατηρεί καλύτερα τις τοπικές σχέσεις μεταξύ των δειγμάτων και χρησιμοποιείται ευρέως για την οπτικοποίηση βαθιών αναπαραστάσεων.

Τα Σχήματα 1 και 2 παρουσιάζουν την προβολή των 2048-διάστατων embeddings του ResNet50 σε δισδιάστατο χώρο.

A placeholder for a PCA plot of ResNet50 embeddings. The plot area is empty, with only the file path 'results/plots/pca_embeddings.png' visible.

results/plots/pca_embeddings.png

Σχήμα 1: Οπτικοποίηση των ResNet50 embeddings μέσω PCA.



Σχήμα 2: Οπτικοποίηση των ResNet50 embeddings μέσω t-SNE.

Όπως παρατηρείται στο Σχήμα 1, ακόμη και μετά από γραμμική προβολή των χαρακτηριστικών σε δύο διαστάσεις, τα πραγματικά και τα συνθετικά βίντεο εμφανίζουν σαφή διαχωρισμό. Παρότι η PCA διατηρεί μόνο μέρος της συνολικής πληροφορίας, οι δύο κατηγορίες παραμένουν σχεδόν πλήρως διαχωρισμένες, γεγονός που υποδηλώνει ότι τα εξαγόμενα χαρακτηριστικά διαθέτουν υψηλή διακριτική ικανότητα.

Η εικόνα γίνεται ακόμη πιο ξεκάθαρη στην περίπτωση της t-SNE (Σχήμα 2), όπου οι δύο κατηγορίες σχηματίζουν δύο διακριτές περιοχές στον χώρο χαρακτηριστικών με ελάχιστη επικάλυψη. Παράλληλα, παρατηρείται η ύπαρξη μικρότερων υποομάδων (clusters) μέσα σε κάθε κατηγορία, οι οποίες πιθανότατα αντιστοιχούν σε διαφορετικούς ομιλητές, εκφράσεις προσώπου ή συνθήκες λήψης.

Η σχεδόν πλήρης διαχωρισιμότητα των δύο κλάσεων εξηγεί την ιδιαίτερα υψηλή απόδοση που επιτυγχάνουν ακόμη και απλοί γραμμικοί ταξινομητές, όπως η Logistic Regression. Τα αποτελέσματα αυτά υποδεικνύουν ότι το μεγαλύτερο μέρος της πληροφορίας που απαιτείται για την ταξινόμηση έχει ήδη κωδικοποιηθεί στις βαθιές αναπαραστάσεις που εξάγει το ResNet50, καθιστώντας λιγότερο αναγκαία τη χρήση πολύπλοκων ταξινομητών.

Συνολικά, η ανάλυση του χώρου χαρακτηριστικών επιβεβαιώνει ότι το προεκπαιδευμένο ResNet50 λειτουργεί ως ιδιαίτερα αποτελεσματικός εξαγωγέας χαρακτηριστικών για το πρόβλημα της ανίχνευσης deepfake βίντεο.

Αξιολόγηση: 5-Fold Cross Validation

Η αξιολόγηση ενός μοντέλου μέσω ενός μόνο διαχωρισμού εκπαίδευσης και αξιολόγησης ενδέχεται να επηρεάζεται από τη συγκεκριμένη επιλογή των δειγμάτων. Για τον λόγο αυτό πραγματοποιήθηκε επιπλέον αξιολόγηση χρησιμοποιώντας 5-fold Stratified Cross Validation.

Σε κάθε επανάληψη, τα δεδομένα χωρίστηκαν σε πέντε ισομεγέθη υποσύνολα διατηρώντας την αναλογία πραγματικών και συνθετικών βίντεο. Τέσσερα υποσύνολα χρησιμοποιήθηκαν για εκπαίδευση και το πέμπτο για αξιολόγηση, ενώ η διαδικασία επαναλήφθηκε πέντε φορές ώστε κάθε δείγμα να χρησιμοποιηθεί μία φορά ως σύνολο αξιολόγησης.

Ως βασική μετρική χρησιμοποιήθηκε το F1-score, καθώς λαμβάνει υπόψη τόσο την ακρίβεια (Precision) όσο και την ανάκληση (Recall), παρέχοντας μία περισσότερο ισορροπημένη αξιολόγηση της απόδοσης.

Τα αποτελέσματα παρουσιάζονται στον Πίνακα 3.

Πίνακας 3: 5-Fold Cross Validation της Logistic Regression.

Fold	F1-score
1	1.0000
2	1.0000
3	1.0000
4	0.9950
5	1.0000
Μέσος Όρος	0.9990
Τυπική Απόκλιση	0.0020

Παρατηρείται ότι η απόδοση παραμένει ιδιαίτερα σταθερή σε όλες τις επαναλήψεις της διασταυρούμενης επικύρωσης, με μέσο F1-score ίσο με 0.999 και εξαιρετικά μικρή τυπική απόκλιση. Το αποτέλεσμα αυτό δείχνει ότι η υψηλή απόδοση του μοντέλου δεν οφείλεται σε κάποιο ευνοϊκό train/test split, αλλά επαναλαμβάνεται με συνέπεια σε διαφορετικούς διαχωρισμούς των δεδομένων.

Η διασταυρούμενη επικύρωση ενισχύει σημαντικά την αξιοπιστία των πειραματικών αποτελεσμάτων και επιβεβαιώνει τη σταθερότητα της προτεινόμενης προσέγγισης.

Συνολική Αποτίμηση του Οπτικού Υποσυστήματος

Συνοψίζοντας, το οπτικό υποσύστημα παρουσίασε ιδιαίτερα υψηλή απόδοση σε όλες τις πειραματικές διαδικασίες που εξετάστηκαν. Οι βαθιές αναπαραστάσεις που εξάγονται από το ResNet50 αποδείχθηκαν ιδιαίτερα αποτελεσματικές για τον διαχωρισμό πραγματικών και συνθετικών βίντεο, επιτρέποντας ακόμη και σε απλούς γραμμικούς ταξινομητές να επιτύχουν σχεδόν τέλεια απόδοση.

Η αξιολόγηση μεταξύ διαφορετικών generators έδειξε ότι τα μοντέλα διατηρούν πολύ υψηλή απόδοση ακόμη και όταν εφαρμόζονται σε συνθετικά βίντεο που έχουν παραχθεί από διαφορετική τεχνική δημιουργίας, γεγονός που αποτελεί ισχυρή ένδειξη καλής γενίκευσης. Επιπλέον, η οπτικοποίηση των embeddings μέσω PCA και t-SNE επιβεβαίωσε ότι οι δύο κατηγορίες διαχωρίζονται σχεδόν πλήρως ήδη στον χώρο χαρακτηριστικών, ενώ η 5-fold διασταυρούμενη επικύρωση κατέδειξε τη σταθερότητα της προτεινόμενης προσέγγισης.

Τα αποτελέσματα αυτά καταδεικνύουν ότι το ResNet50 μπορεί να χρησιμοποιηθεί αποτελεσματικά ως εξαγωγέας χαρακτηριστικών για την ανίχνευση deepfake βίντεο, παρέχοντας ισχυρές αναπαραστάσεις χωρίς να απαιτείται εκπαίδευση ενός πολύπλοκου συνελκτικού δικτύου από την αρχή.

Συζήτηση

Τα πειράματα ανέδειξαν τις διαφορές μεταξύ κλασικών προσεγγίσεων μηχανικής μάθησης και μοντέλων βαθιάς μάθησης για την ανίχνευση συνθετικών βίντεο ομιλίας.

Τα μοντέλα που βασίζονται σε χαρακτηριστικά του ResNet50 πέτυχαν υψηλή απόδοση, γεγονός που υποδεικνύει ότι τα προεκπαιδευμένα συνελκτικά δίκτυα είναι ικανά να εξάγουν ιδιαίτερα διακριτικές οπτικές αναπαραστάσεις ακόμη και χωρίς εκπαίδευση από την αρχή.

Η χρήση χρονικής πληροφορίας μέσω του LSTM επέτρεψε την αξιοποίηση της δυναμικής των κινήσεων του προσώπου και των χειλιών. Τα αποτελέσματα δείχνουν ότι η χρονική πληροφορία μπορεί να συμβάλει θετικά στην ανίχνευση συνθετικών βίντεο, ιδιαίτερα σε περιπτώσεις όπου οι οπτικές ασυνέπειες εμφανίζονται σε επίπεδο ακολουθίας και όχι σε μεμονωμένα καρέ.

Αντίθετα, η προσέγγιση που βασίζεται σε χειροποίητα χαρακτηριστικά κίνησης χειλιών παρουσιάζει αυξημένη ερμηνευσιμότητα, αλλά περιορίζεται από την ποσότητα της πληροφορίας που μπορεί να περιγράψει. Παρότι χαρακτηριστικά όπως το άνοιγμα και η κίνηση του στόματος μπορούν να αποκαλύψουν ορισμένες ανωμαλίες, δεν είναι πάντοτε επαρκή για την πλήρη περιγραφή της οπτικής συμπεριφοράς ενός συνθετικού βίντεο.

Ιδιαίτερο ενδιαφέρον παρουσιάζουν τα πειράματα γενίκευσης μεταξύ διαφορετικών γεννητριών deepfake. Σε αντίθεση με τον κλασικό τυχαίο διαχωρισμό των δεδομένων, το σενάριο αυτό προσομοιώνει συνθήκες πραγματικού κόσμου, όπου το σύστημα καλείται να ανιχνεύσει τεχνικές δημιουργίας που δεν έχουν εμφανιστεί κατά την εκπαίδευση. Η διατήρηση υψηλής απόδοσης σε τέτοια πειράματα αποτελεί σημαντική ένδειξη πραγματικής ικανότητας γενίκευσης.

Τέλος, η πολυτροπική σύντηξη αναμένεται να βελτιώσει περαιτέρω την απόδοση του συστήματος, αξιοποιώντας τη συμπληρωματικότητα μεταξύ οπτικής και ακουστικής πληροφορίας. Η ύπαρξη ενδείξεων παραποίησης και στις δύο τροπικότητες καθιστά δυσκολότερη την απόκρυψη συνθετικού περιεχομένου και ενισχύει τη συνολική αξιοπιστία του συστήματος.

Συμπεράσματα και Μελλοντική Εργασία

Στην παρούσα εργασία μελετήθηκε το πρόβλημα της ανίχνευσης συνθετικών βίντεο ομιλίας μέσω πολυτροπικής ανάλυσης. Αναπτύχθηκαν ανεξάρτητα οπτικά και ακουστικά υποσυστήματα, ενώ εξετάστηκε και η δυνατότητα συνδυασμού των δύο πηγών πληροφορίας μέσω μηχανισμών σύντηξης.

Για το οπτικό σκέλος αξιολογήθηκαν τόσο κλασικές όσο και βαθιές προσεγγίσεις μηχανικής μάθησης, συμπεριλαμβανομένων μοντέλων Logistic Regression, MLP, LSTM και Random Forest. Παράλληλα, διερευνήθηκε η επίδραση της χρονικής πληροφορίας καθώς και η δυνατότητα αξιοποίησης γεωμετρικών χαρακτηριστικών της περιοχής του στόματος.

Ιδιαίτερη έμφαση δόθηκε στην αξιολόγηση γενίκευσης μέσω πειραμάτων open-generator, τα οποία προσομοιώνουν πιο ρεαλιστικά σενάρια χρήσης και επιτρέπουν την εκτίμηση της ανθεκτικότητας των μοντέλων σε άγνωστες τεχνικές παραγωγής deepfake.

Τα αποτελέσματα της εργασίας αναδεικνύουν τη σημασία της αξιοποίησης πολλαπλών πηγών πληροφορίας για την ανίχνευση συνθετικού περιεχομένου και επιβεβαιώνουν τη δυναμική των πολυτροπικών προσεγγίσεων στον συγκεκριμένο τομέα.

Ως μελλοντική εργασία προτείνεται η αξιοποίηση πιο σύγχρονων αρχιτεκτονικών βασισμένων σε Transformers τόσο για την οπτική όσο και για την ακουστική τροπικότητα. Επιπλέον, θα μπορούσε να διερευνηθεί η χρήση end-to-end πολυτροπικών μοντέλων τα οποία εκπαιδεύονται ταυτόχρονα σε εικόνα και ήχο, καθώς και η αξιολόγησή τους σε μεγαλύτερα και περισσότερο ετερογενή σύνολα δεδομένων deepfake.